

일반논문

인공지능 거버넌스에서 신뢰 개념에 대한 고찰 및 정책 유형화 연구[†]

A Conceptual Framework for the Trust in Artificial Intelligence in AI Governance and Policy Typology

우 지 숙(Jisuk Woo)* · 김 수 지(Suji Kim)**

목차

- I. 들어가며
- II. 인공지능 신뢰의 개념적 틀
- III. 인공지능 신뢰 정책의 유형화
- IV. 결론 및 정책적 함의

〈국문초록〉

인공지능이 급속히 확산되면서 인공지능을 수용할 수 있는 전제 조건으로서 인공지능 신뢰를 촉진하기 위한 정책적 노력이 구체화되고 있다. 그러나 인공지능 신뢰가 무엇을 의미하는지, 신뢰와 위험(risk)의 관계는 무엇인지, 신뢰는 어떤 과정을 거쳐 형성되는지, 이를 촉진하기 위해 정책은 어떤 역할을 수행해야 하는지 여전히 불분명하다. 본 연구는 이론적, 개념적 검토를 통해 신뢰는 위험이 존재하지 않는 상태에서 나타나는 것이 아니라 위험의 존재에도 ‘불구하고’ 그로 인해 취약해지는 것을 감수하려는 태도와 의지이며, 이러한 신뢰의 형성 과정에는 인공지능 신뢰성에 대한 이용자의 평가가 큰 영향을 미치지만, 신뢰성이 곧바로 신뢰로 연결되는 것은 아니라는 점에서 신뢰의 형성은 복잡하고 능동적인 과정임을 강조하였다. 또한 본 연구는 인공

지능 신뢰에 대한 접근방법을 ‘위험 축소형’과 ‘신뢰성 향상형’으로 나누고, 인공지능 신뢰 정책을 강화, 준수, 설명, 참여의 네 유형으로 분류하였다. 강화 정책과 준수 정책은 위험 축소 접근에 근거한 것으로서 인공지능의 위험 수준을 줄이기 위한 기술적 조치들에 집중하거나(강화), 기업의 인공지능 개발 과정에서 발생할 수 있는 위험 요소를 제거하고자 한다(준수). 설명 정책과 참여 정책은 신뢰성 향상 접근방법에 근거하여 인공지능의 신뢰성을 평가하고 개선하는 과정에 초점을 맞추며, 인공지능 기술의 신뢰성과 관련된 정보를 이용자에게 제공하도록 독려하거나(설명), 이용자가 인공지능 기업의 신뢰성을 평가하고 인공지능의 신뢰성에 영향을 미칠 수 있는 의사결정 과정에 참여할 수 있는 환경을 조성하고자 한다(참여). 신뢰의 개념적 틀에 대한 고찰과 인공지능 신뢰 정책의 유형화에 관한 본 연구는 인공지능 신뢰 정책이 인공지능의 위험을 축소하기 위한 노력뿐 아니라 이용자가 인공지능 기술과 기업의 신뢰성을 적극적으로 평가하고 관련 의사결정 과정에 참여할 수 있는 환경을 마련하는 데 초점을 맞출 필요가 있다는 점을 시사한다.

I. 들어가며

인공지능(AI)은 우리 삶의 모든 부분에 깊숙이 들어와 있으며 사회적으로도 광범위한 변화를 불러오고 있다. 그동안 인공지능 기술은 데이터 분석과 최적화, 자동화 등의 기능을 통해 다양한 산업 분야에

[†] 투고일자 2024.11.2. 심사일자 2024.11.25. 게재 확정일자 2024.11.25.

* 주저자, 서울대학교 행정대학원 교수, 서울대학교 한국행정연구소 겸임연구원

** 교신저자, 서울대학교 행정대학원 박사과정

서 변화와 혁신을 가져왔고, 최근 생성형 AI 기술의 발전으로 개인들의 AI 도구 활용도 기하급수적으로 늘어나고 있으며 이에 대한 투자 역시 폭발적으로 증가하고 있다. 이처럼 인공지능은 인류에게 큰 혜택을 가져올 수 있지만, 동시에 오작동이나 남용 등으로 인한 폐해의 가능성, 그리고 무엇보다도 불투명성과 예측 불가능성에 대한 우려로 인해 인공지능에 대한 국가적 개입의 필요성에 대한 논의가 급물살을 타고 있다. 기술의 발전은 대체로 새로운 위험을 가져오게 되고 기술의 발전 속도가 빠를수록 그 위험도 급격히 높아가기 때문에 엄청난 속도와 성능으로 진화하고 있는 인공지능에 대한 대응에 국가의 역할이 존재한다는 점에 대해서는 이견을 달기 어렵다.¹⁾ 그러나 태생부터 정의하기 매우 어려웠고 최근 기계학습, 심층학습, 언어모델 등을 통해 급격하게 변화하며 발전하고 있는 인공지능을 명시적인 규칙으로 구성된(rule-based) 기존의 법제도 체계 내에 포섭하는 것은 매우 어려운 일이다.²⁾ 무엇보다도 인공지능 기술의 이용이 실제로 얼마나 어떻게 법익의 침해를 초래하거나 초래할 우려가 있는지 충분한 과학적 근거를 갖고 예견할 수 없다는 불확실성으로 인해 기존 법제도로 인공지능을 규율하는 것은 과잉 규제 또는 불합리한 규제가 될 수 있다는 우려가 있다.³⁾ 이에 각국 정부는 인공지능 기술의 발전과 이를 바탕으로 한 산업 및 사회 혁신의 가능성을 저해하지 않으면서도 인간의 가치와 안전을 지키기 위한 거버넌스 방안을 마련하기 위해 노력해 왔다. 인공지능 거버넌스의 구축은 인공지능 기술 선도국인 미국, 유럽, 캐나다, 중국을 비롯하여 우리나라, 일본, 싱가포르 등에서도 중요한 국가적 과제로 부상하였다. 글로벌 제도 경쟁의 시대가 열렸다고 해도 과언이 아닐 정도로 인공지능 거버넌스는 전 세계적인 과제가 된 것이다.⁴⁾

인공지능 거버넌스는 다양한 내용과 목표를 포괄하며, 특히 인공지능의 안전성과 신뢰성의 확보를 위한 정책들이 핵심적이라고 할 수 있다. 그중에서도 인공지능에 대한 신뢰(trust in AI)는 인공지능 수용의 선결 요건이 될 수 있다는 점에서 각국 정부와 국제사회의 관심을 끌어왔다. 신뢰는 사회 구성원 간 상호작용과 새로운 기술 수용에 핵심적인 역할을 하기 때문이다.

예를 들어 유럽연합(EU)은 인공지능 시스템 전반에 적용되는 세계 최초의 포괄적인 규제 체계로 잘 알려진 EU 인공지능법(EU AI Act)을 제정하여 AI 시스템을 허용되지 않는 위험(Unacceptable risk AI), 고위험(High-risk AI), 제한된 위험(Limited risk AI), 최소위험(Minimal risk AI)으로 나누어 차등적으로 규제하는 ‘위험기반 접근 방식(risk-based approach)’을 채택하였다. 이러한 리스크 관리 기반 패러다임은 인공지능을 규제하기 위해 새롭게 나타난 방식이 아니라 일찍부터 의약품, 식품, 과학기술 등 여러 분야에서 안전성 관리를 위해 채택돼 오던 방식이지만, 최근 들어 인공지능과 같이 변화하는 기술 환경에 조응하는 체계로서의 중요성이 더욱 주목받고 있다.⁵⁾ EU 인공지능법은 2024년 제정되고 동년 8월 1일부터 발효되었지만, 유럽연합집행위원회가 2021년 초안을 공개한 후 오랜 토론과 입법 절차를 거쳐 제정되었다.⁶⁾ 이 법에 큰 영향을 끼친 ‘신뢰할 수 있는 인공지능 윤리 가이드라인(Ethics Guideline for Trustworthy AI)’은 유럽연합집행위원회의 인공지능고위전문가그룹(High-Level Expert Group, HLEG)에 의해 2019년 4월 발표된 이후 EU 인공지능법(AI Act)에 병합되었는데, 신뢰할 수 있는 인공지능(trustworthy AI) 달성을 목적으로 한 EU의 첫 정책적 시도였다는 점에서 큰 의미가 있다.

1) 김태오, “사이버 안전의 공법적 기초 - 독일의 IT 기본권과 사이버 안전법을 중심으로”, 『행정법연구』, 제45호, 행정법이론실무학회, 2016, 113면; 선지원, “인공지능의 사회적 수용을 위한 국가법의 과제”, 『국가법연구』, 제16권 제3호, 한국국가법학회, 2020, 2-4면.
2) 윤혜선, “인공지능의 사회적 수용성과 법제도의 기능적 관계에 관한 소고”, 『경제규제와 법』, 제14권 제1호, 서울대학교 공익산업법센터, 2021, 33-35면.
3) 윤혜선, 위의 글, 35-38면.

4) 윤혜선, “인공지능 거버넌스의 국제 동향과 한국의 좌표: 현황과 도전과제”, 서울대학교 공익산업법센터 제24회 국제학술대회, 『인공지능의 시대를 향한 규제 거버넌스의 모색』, 2024, 10, 3.
5) 윤혜선, 앞의 글, 2021; 윤혜선, “리스크 규제에 관한 공법적 연구: 식품안전법제를 중심으로”, 박사학위논문, 서울대학교, 2009.
6) 최경진/강지원/김법연/김형준/박신욱/오정인/채기현, 『EU 인공지능법』, 박영사, 2024.

미국은 2020년 ‘국가인공지능이니셔티브법(National Artificial Intelligence Initiative Act of 2020)’, ‘정부 인공지능법(AI in Government Act of 2020)’ 등 연방법을 제정해 인공지능 연구 투자를 늘리고 관련 산업을 진흥하고자 했고, 2023년에는 ‘안전하고 보안이 보장되며 신뢰할 수 있는 인공지능 개발 및 사용 행정명령(Executive Order: Safe, Secure, and Trustworthy Development and Use of Artificial Intelligence)’을 제정하여 연방정부와 관련 기관이 준수해야 하는 인공지능 개발 및 사용과 관련한 8개 원칙(안전과 보안, 혁신 및 경쟁, 근로자 지원, 형평과 시민권 보호, 소비자 보호, 개인정보보호, 연방기관의 인공지능 사용지침, 국제관계 리더십)과 우선순위를 정하는 한편 다양한 연방기관들에 대해 일정 기간 내에 필요한 조치를 실행하도록 하였다. 2023년 1월에는 국립표준기술연구소(National Institute of Standards and Technology, NIST)가 ‘인공지능 위험 관리프레임워크(AI Risk Management Framework; AI RMF)’를 발표하면서 신뢰할 수 있는 인공지능의 특성과 이를 달성하기 위한 방법을 제시하였다. NIST는 조직 내외부 이해관계자의 관점에서 인공지능의 위험을 발견, 측정, 관리하고 이를 해결하기 위한 의사결정 체계를 개선하는 과정인 AI RMF Core를 제시함으로써 인공지능을 설계-개발-배포-사용하는 전 과정에서의 신뢰성을 평가하고 인공지능 기술의 사회적 수용을 증진하고자 하였다.

이렇게 인공지능에 대한 신뢰는 주요국의 핵심적인 정책 목표가 되고 있고, 특히 EU와 미국의 신뢰성 있는 인공지능(trustworthy AI)에 대한 가이드라인들은 각국 정부의 정책과 기업들의 경영 전략에도 영향을 미칠 것으로 예상된다. 점에서 중요한 역할을 할 것으로 보인다. 그런데 문제는 실제로 인공지능에 대한 신뢰가 무엇을 의미하는지, 어떻게 달성되는 것인지, 특히 이용자의 입장에서 무엇을 의미하는지에 대해 구체적으로 정의되고 있지 않다는 점이다. 신뢰의 개념은 그 자체로서 정의하기 어려운 개념이기도 하다. 그동안 심리학, 경제학, 국제 비즈니스, 철학, 조직 관리, 공학 등 학문 분야마다 신뢰를 각기 다른

측면에서 조명하고 정의해 왔다는 점에서도 인공지능 신뢰를 정의하는 일은 더욱 어려운 작업이다.⁷⁾ 그러다 보니 인공지능 신뢰는 거버넌스와 정책의 목표로서 광범위한 공감대를 형성하였음에도 불구하고 그 의미가 불분명하게 되고, 실천적 의미를 상실한 채 단순한 유행어가 되어버릴 수 있다는 우려의 목소리마저 들린다.⁸⁾

이에 본 연구에서는 인공지능 정책의 목표로 제시되고 있는 인공지능 신뢰의 의미를 체계적으로 고찰해 보고자 한다. 먼저 정책적 관점에서 보았을 때 인공지능에 대한 신뢰를 어떻게 개념화할 수 있는지 살펴보고 인공지능 신뢰의 개념적 틀을 구성해 보고자 한다. 그리고 이렇게 구성된 인공지능 신뢰의 개념적 틀에 근거하여 인공지능 신뢰와 관련된 정책을 어떻게 유형화할 수 있는지 살펴볼 것이다. 이를 통해 인공지능 신뢰 정책을 분석하고 비교할 수 있는 이론적 틀을 제공할 뿐만 아니라 정책을 설계하는데 필요한 실천적 지침을 제공하는 것이 본 연구의 목표다.

II. 인공지능 신뢰의 개념적 틀

1. 기술에 대한 신뢰와 신뢰의 개념

이론적으로 신뢰 개념은 대인 관계를 전제로 발전해 왔다. 그러므로 비인간 행위자인 기술에 신뢰 개념을 확장하여 적용할 수 있는지 의문이 제기될 수 있다. 이러한 의문은 신뢰에 대한 철학적, 윤리적 연구에서 종종 발견된다. 기술은 자율성, 도덕성이 없으며 의도와 상관없이 다만 미리 프로그램된 기능을 실행할 뿐이므로 신뢰 주체를 배신할 수도 없고, 따라서 인간과 같은 방식으로 신뢰할 수도 없다는 것이

7) Peter Andras et al., “Trusting Intelligent Machines: Deepening Trust Within Socio-Technical Systems”, 『IEEE Technology and Society Magazine』, vol. 37, no. 4, IEEE, 2018, 77면.

8) Karoline Reinhardt, “Trust and Trustworthiness in AI Ethics”, 『AI and Ethics』, Vol. 3, No. 3, Springer, 2023, 735-736면.

다.9) 이러한 관점은 인공지능 정책의 목표가 신뢰가 아닌 안정성(reliability)¹⁰⁾으로 대체되어야 한다는 주장으로 이어진다.¹¹⁾ 그러나 인간 행위자와 기술 행위자의 경계는 흐려지고 있다. 많은 기술 철학자는 기술이 도덕적 행위자이며 인간이 기술에 대한 신뢰를 토대로 기계와 상호작용하고 있다는 사실을 지적한다.¹²⁾ 경험적 증거들 또한 인간이 기술을 사회적, 도덕적 행위자로 간주하고 행동함을 보여준다. Reeves & Nass는 인간과 기술의 상호작용에 대한 실험 연구에서 인간이 기계와 상호작용할 때 사회적 규범에 따라 행동한다는 사실을 반복적으로 관찰한 바 있다.¹³⁾ 인간은 아주 작은 단서만 주어져도 마치 인간을 대하듯 사회적 규범에 따라 기술을 대할 뿐 아니라, 기술 또한 호혜성을 갖추어 인간을 대할 것이라 기대한다는 것이다.¹⁴⁾ 이에 기술을 사회적 행위자로 간주하고 인간과 기술 간의 관계로까지 윤리의 범주를 확장할 수 있게 된다. 인공지능을 비롯하여 기술은 이미 사회적 행위자로서 이용자와 상호작용하고 있다. 이에 본 연구에서는 그동안의 학술적 연구에서 발전되어 온 신뢰의 개념을 인공지능에 대한

신뢰 논의에 적용하여 개념적 틀을 찾아가 보고자 한다.

사회과학의 여러 학제는 신뢰 개념을 달리 정의해 왔을 뿐만 아니라 서로 다른 측면에 초점을 맞추어 연구해 왔다. 경제학에서 신뢰는 상대방과의 상호작용에서 상대방을 믿은 데 따른 이익과 배반에 따른 손실을 비교한 결과로써 나타나며,¹⁵⁾ 주로 게임이론 또는 거래비용의 관점에서 분석된다.¹⁶⁾ 반면 사회학의 관점에서 신뢰는 단순한 이익 추구를 넘어서는 사회질서의 근원적 요소로서,¹⁷⁾ 신뢰의 결과 사회 구성원들은 서로의 존재에 의해 구성되는 예상 가능한 미래에 따라 행동할 수 있게 된다고 본다.¹⁸⁾ 한편, 행정학은 신뢰가 정치체제의 성과와 정당성, 정책 수용에 미치는 영향에 주목하며,¹⁹⁾ 특히 정부에 대한 신뢰를 불확실한 상황에서 국민이 정부의 행동에 대하여 취하는 긍정적인 기대나 심리적 지지로 정의하고 그 효과와 영향 요인들을 실증적으로 연구해 왔다.²⁰⁾ 반면 기술적인 측면을 강조하는 컴퓨터공학에서는 신뢰 개념을 시스템의 안정성이나 통제 가능성, 품질 관리, 보안 등과 관련하여 바라보는 경향을 보였다.²¹⁾

- 9) 신뢰의 일반 개념과 배신 간의 관계에 대해서는 Annette Baier, "Trust and Antitrust", 『Ethics』, Vol. 96, No. 2, The University of Chicago Press, 1986, 234-235면.
- 10) 우리말에서는 신뢰 대상이 신뢰받을 수 있도록 하는 성질들의 집합으로서 신뢰성(trustworthiness)과 동일한 방법을 반복했을 때 사전에 설계한 의도대로 일관된 결과가 반복적으로 관찰되는 안정성(reliability)이 구분되지 않고 '신뢰성'이라 번역됨에 따라 논의가 더욱 어려워지는 측면이 있다. 본 논문에서는 각각을 신뢰성과 안정성으로 구분한다.
- 11) Mark Ryan, "In AI We Trust: Ethics, Artificial Intelligence, and Reliability", 『Science and Engineering Ethics』, Vol. 26, No. 4, Springer, 2020.
- 12) Mark Coeckelbergh, "Can We Trust Robots?", 『Ethics and Information Technology』, Vol 14, No. 1, Springer, 2012; Luciano Floridi, "Faultless Responsibility: On the Nature and Allocation of Moral Responsibility for Distributed Moral Actions", 『Philosophical Transactions of the Royal Society A: Mathematical, Physical and Engineering Sciences』, The Royal Society Publishing, 2016; Luciano Floridi/J.W.Sanders, "On the Morality of Artificial Agent", 『Minds and Machines』, Vol 14, Springer, 2004.
- 13) Byron Reeves/Clifford Nass, 『The Media Equation: How People Treat Computers, Television, and New Media Like Real People and Places』, Center for the Study of Language and Information, Cambridge University Press, 1996.
- 14) 위의 책, 19-36면.

- 15) Debra L. Shapiro/Blair H. Sheppard/Lisa Cheraskin, "Business on a Handshake", 『Negotiation Journal』, Vol. 8, No. 4, MIT Press, 1992.
- 16) Peter Andras et al., 앞의 글; Balázs Bodó, "Mediated Trust: A theoretical Framework to Address the Trustworthiness of Technological Trust Mediators", 『New Media & Society』, Vol. 23, No. 9, SAGE, 2021, 2674면.
- 17) Annette Baier, 앞의 글; J. David Lewis/Andrew Weigert, "Trust as a Social Reality", 『Social Forces』, Vol. 63, No. 4, Oxford University Press, 1985.
- 18) David Lewis/Andrew Weigert, 앞의 글, 968면.
- 19) 심준섭, "원자력 발전소에 대한 신뢰, 인식된 위험과 혜택, 그리고 수용성", 『한국행정학회보』, 제18권 제4호, 한국정책학회, 2009; 최태현, "거버넌스에 대한 가치 지향과 신뢰", 『한국행정학회보』, 제49권 제2호, 한국행정학회, 2015.
- 20) 박통희, "신뢰의 개념에 대한 비판적 검토와 재구성", 『한국행정학회보』, 제33권 제2호, 한국행정학회, 1999; 채원호/손호중, "정책실패와 신뢰", 『한국행정논집』, 제17권 제1호, 한국정부학회, 2005; 이수영/이하영, 『정부신뢰 2요인론: 신뢰 요인과 불신 요인에 대한 탐색』, 서울대학교 행정대학원 한국행정연구보고서 1, 윤성사, 2022.
- 21) Donovan Artz/Yolanda Gil, "A Survey of Trust in Computer Science and the Semantic Web", 『Journal of Web Semantics』, Vol. 5, No. 2, SWSA, 2007.

신뢰에 관한 이론적, 실증적 연구를 오랫동안 축적해 온 심리학은 신뢰를 타인이 자신의 기대에 맞게 행동할 것이라는 믿음으로, 상대방의 배신에 따른 위험을 감수하면서 타인을 믿으려는 태도로 정의하며, 신뢰 대상의 의도나 동기에 대한 평가 과정을 강조하는 경향을 보인다.²²⁾ 최근 인공지능에 대한 신뢰를 연구한 Andras et al.도 다양한 학제들의 신뢰에 대한 정의와 접근법을 종합했을 때 공통으로 드러나는 개념이 “불확실한 상황에서 위험을 감수하려는 의지(willingness to take risk under uncertainty)”라고 지적하였다.²³⁾ Laux et al.은 신뢰를 “신뢰 대상의 의도에 대한 위험과 불확실성의 조건 속에서 자신을 취약한 위치에 노출하려는 의지(the willingness of one party to expose themselves to a position of vulnerability towards a second party under conditions of risk and uncertainty as regards the intentions of that second party)”로 정의하였다.²⁴⁾ 이때 위험은 리스크(risk)를 지칭한다. 우리말은 영어의 risk뿐만 아니라 danger, hazard 등도 모두 ‘위험’으로 칭하다 보니 개념적 혼란이 여지가 있다. 절대적 부정의 의미를 가지는 danger와 달리 risk는 위험의 정도만이 아니라 발생가능성(probability 또는 likelihood)까지 내포한다.²⁵⁾ 위험기반 규제, 위험 관리 등에서 사용되는 ‘위험’은 리스크를 의미하는 것으로서, 본 연구에서는 위험과 리스크를 교차적으로 사용한다. 여기서 우리는 신뢰가 위험을 원천 제거하

는 것이 아니라, 위험이 존재함에도 ‘불구하고’ 인간이 가지게 되는 어떤 태도나 의지라는 사실에 주목해야 한다. 이는 리스크 기반 규제 및 리스크 관리 접근이 인공지능 거버넌스에서 주목받고 있는 현 상황에서 매우 중요한 함의를 갖는다. 이에 다음 장에서 신뢰와 위험의 관계에 대해 논하고자 한다.

2. 신뢰와 위험(risk)

신뢰의 정의에서 신뢰가 위험이 없는 상태를 뜻하지 않으며, 오히려 위험에 대한 인식이 신뢰 형성의 선제 조건이라는 점에 주목할 필요가 있다. 신뢰의 결과 신뢰 주체(trustor)는 신뢰 대상(trustee)의 행위에 의해 영향을 받는 취약한 위치에 놓이게 되기 때문이다. 신뢰 연구 학자들도 위험의 존재를 신뢰에 선행하는 요인으로서 강조해 왔다. Baier는 신뢰를 미처 예상하지 못한 타인의 악의(또는 선의의 부족)에 대한 자신의 취약성을 받아들이는 것이라고 보았다.²⁶⁾ 신뢰 주체의 신뢰와 무관하게 신뢰 대상은 악의를 가지고 있거나 또는 악의는 없을지언정 선의를 갖고 있지 않을 수 있기 때문이다. 신뢰의 결과로써 신뢰 주체는 타인의 의지에 의존하는 데서 오는 취약성, 즉 리스크를 감수한다.²⁷⁾ Lewis & Weigert도 신뢰 주체가 위험을 감수하고 상호작용에 대한 믿음의 도약을 이룬다는 측면을 강조하였다.²⁸⁾ 이처럼 위험이 전제되지 않는다면 신뢰는 불필요할 뿐 아니라 만들어질 수도 없다.

조직 신뢰 연구에 오랫동안 천착해온 노스캐롤라이나 주립대학 Mayer 교수도 위험에 대한 인식이 신뢰의 전제 조건이라고 보았다.²⁹⁾ Mayer et. al.은 조직 신뢰의 통합 모델을 개발하였는데 이 모델은 일종의 순환 구조(feedback loop)로서 제안되었다.³⁰⁾ 즉

22) Roger C. Mayer/James H. Davis/F. David Schoorman, “An Integrative Model of Organizational Trust”, 『Academy of Management Review』, Vol 20, No. 3, Academy of Management, 1995; F. David Schoorman/Roger C. Mayer/James H. Davis, “An Integrative Model of Organizational Trust: Past, Present, and Future”, 『Academy of Management Review』, Vol. 32, No. 2, Academy of Management, 2007; Peter Andras et al., 앞의 글.

23) Peter Andras et al., 앞의 글, 77면.

24) Johann Laux/Sandra Wachter/Brent Mittelstadt, “Trustworthy Artificial Intelligence and the European Union AI act: On the Conflation of Trustworthiness and Acceptability of Risk”, 『Regulation & Governance』, Vol 18, No. 1, John Wiley & Sons, 2024, 5면.

25) 남구현, “인공지능 규율에 있어 위험기반 접근 방식의 적합성 고찰”, 『법학논총』, 제36호 제1호, 국민대학교 법학연구소, 2023, 163-165면.

26) Annette Baier, 앞의 글, 235면.

27) 위의 글, 239면.

28) David Lewis/Andrew Weigert, 앞의 글, 970면.

29) Mayer et. al. (1995)은 신뢰 개념이 위험을 전제 조건으로 한다는 점에서 협력, 예측 가능성, 확신 등의 연관 개념과 구분됨을 보인다. Roger C. Mayer/James H. Davis, F. David Schoorman, 앞의 글, 709-714면.

30) Roger C. Mayer/James H. Davis, F. David Schoorman, 앞의 글.

위험을 감수하는(risk-taking) 상황에서 신뢰의 결과가 발생하고, 이를 신뢰 주체가 인식함으로써 신뢰 대상에 대한 신뢰 주체의 재평가가 이루어진다는 것이다.³¹⁾ 이러한 모델은 우리가 신뢰를 리스크가 없는 상태로 바라보아서는 안 된다는 사실뿐 아니라, 신뢰를 단면적인 어떤 상태로 보기보다는 신뢰 주체와 신뢰 대상 간에 끊임없이 형성되고 변화하고 테스트되는 역동적인 과정으로 보아야 한다는 점을 시사한다. 신뢰의 형성 과정에 대한 심층적 연구는 본 논문의 범위를 벗어나는 것이지만 인공지능 신뢰를 도모하고자 하는 정책들이 신뢰의 형성 과정을 고려하여 만들어져야 한다는 점은 분명하다. 즉, 인공지능에 대한 신뢰가 인공지능과의 상호작용에서 그와 관련된 리스크에도 ‘불구하고’ 인공지능을 사용하고자 하는 이용자의 태도와 의지, 그리고 그에 따른 행동을 의미하는 것이라면 인공지능 신뢰를 높이기 위한 정책 역시 인공지능의 리스크를 줄이는 데만 중점을 두어서는 큰 한계를 갖게 된다. 그러한 측면에서 다음 장에서는 최근의 인공지능 거버넌스 논의에서 자주 나타나는 신뢰성 있는 인공지능(trustworthy AI)의 개념이 인공지능에 대한 신뢰(trust in AI)와 어떤 차이가 있는지 살펴보고자 한다.

3. 신뢰(trust)와 신뢰성(trustworthiness)

인공지능 시스템과의 상호작용에서 이용자들은 개인정보 유출, 편견의 심화,³²⁾ 허위정보 생성,³³⁾ 성

착취물 제작,³⁴⁾ 창작자의 권리 침해³⁵⁾ 등과 같은 위험에 노출되어 있다. 신뢰가 ‘관계에서 위험을 감수하고자 하는 의지’를 의미함을 고려하면 인공지능 신뢰는 이러한 위험에도 불구하고 그것을 수용하도록 하는 이용자의 판단으로 이해할 수 있다. 이러한 신뢰는 상대방의 신뢰성(trustworthiness)에 대한 긍정적인 평가에 근거한다. 신뢰와 신뢰성은 개념적으로 구분된다. 신뢰성은 신뢰받는 신뢰 대상의 특성이고 신뢰는 신뢰 주체의 태도이다.³⁶⁾ 즉 신뢰는 신뢰 주체가 신뢰 대상을 복합적으로 평가하여 내린 판단이며,³⁷⁾ 신뢰성은 신뢰 대상이 신뢰받을 수 있도록 하는 성질들의 집합이다.³⁸⁾ 그렇다면 신뢰할 수 있는 행위자(trustworthy actor)란 그가 신뢰받고 있는지 여부와 무관하게 이미 신뢰에 부응할 수 있는 특성들을 갖추고 있다고 할 수 있다.³⁹⁾ 신뢰성이 있다고 해서 곧바로 신뢰받는 것은 아니지만, 신뢰성은 신뢰를 얻는 데에 도움을 주는 중요한 요소라는 것이다.⁴⁰⁾

신뢰성의 구체적인 요소는 무엇일까. Mayer et al.은 신뢰성이 능력(ability), 선의(benevolence), 도덕성(integrity)의 세 요소로 구성된다고 보았다.⁴¹⁾ 신뢰성의 세 요소는 이후 신뢰 연구들에서 폭넓게 활용되었다.⁴²⁾ Lee & See는 신뢰 개념이 인간-기계 상호

Science Advances, Vol.9, No.26, Science, 2023.

31) Roger C. Mayer/James H. Davis, F. David Schoorman, 앞의 글, 715면.

32) Emily M Bender/Timnit Gebru/Angelina McMillan-Major/Shmargaret Shmitchell, “On the Dangers of Stochastic Parrots: Can Language Models Be Too Big?”, 『Proceedings of the 2021 ACM conference on Fairness, Accountability, and Transparency』, 2021; Joy Buolamwini/Timnit Gebru, “Gender Shades: Intersectional Accuracy Disparities in Commercial Gender Classification”, 『Proceedings of the 2021 ACM conference on Fairness, Accountability, and Transparency』, 2018; Jane E. Fountain, “The Moon, the Ghetto and Artificial Intelligence: Reducing Systemic Racism in Computational Algorithms”, 『Government Information Quarterly』, Vol. 39, No. 2, Elsevier, 2022.

33) Giovanni Spitale/Nikola Biller-Andorno/Federico Germani, “AI Model GPT-3 (Dis)informs Us Better than Humans”, 『

34) David Thiel, “Identifying and Eliminating CSAM in Generative ML Training Data and Models”, 『Stanford Digital Repository』, Stanford Internet Observatory Cyber Policy Center, 2023.

35) Peter Henderson/Xuechen Li/Dan Jurafsky/Tatsunori Hashimoto/Mark A. Lemley/ Percy Liang, “Foundation Models and Fair Use”, arXiv preprint arXiv:2303.15715, 2023.

36) Graham Dietz/Deanne N. Den Hartog, “Measuring Trust Inside Organisations”, 『Personnel Review』, Vol. 35, No. 5, Emerald Group Publishing, 559면.

37) 위의 글, 560-563면.

38) Roger C. Mayer/James H. Davis/F. David Schoorman, 앞의 글, 716-724면.

39) Mark Ryan, 앞의 글, 4면.

40) 위의 글, 4면.

41) Roger C. Mayer/James H. Davis, F. David Schoorman, 앞의 글.

42) 이수영/이하영, 앞의 책, 29-32면; Graham Dietz/Deanne N. Den Hartog, 앞의 글, 568-569면; Stephen L. Jones/Priti Pradhan Shah, “Diagnosing the Locus of Trust: A Temporal Perspective for Trustor, Trustee, and Dyadic Influences on Perceived Trustworthiness”, 『Journal of Applied Psychology』, Vol. 101, No. 3, American Psychological Association,

작용에도 적용될 수 있음을 역설하며 신뢰성의 세 요소를 기술에까지 확장 적용할 것을 제안하고, 능력, 선의, 도덕성을 각각 성능(performance), 목적(purpose), 절차(process)로 재개념화하였다.⁴³⁾ 오늘날 인공지능 신뢰를 주제로 한 다수의 연구 또한 성능, 목적, 절차를 인공지능 신뢰의 세 요소로 다루고 있다.⁴⁴⁾

신뢰성에 대한 평가는 신뢰 대상을 신뢰하기 위한 중요한 과정이며, 대상의 신뢰성을 평가하기 위해서는 그가 무엇을, 왜, 어떻게 하는지와 관련된 정보를 알 수 있어야 한다. 즉 신뢰 대상의 행동, 의도 및 기본 원칙이 투명하게 공개되어야 한다.⁴⁵⁾ 정보가 제공되지 않은 상태에서 신뢰 여부를 판단하는 것은 불가능하며, 허위정보에 근거하여 판단해야 한다면 잘못된 판단을 하게 된다. 이러한 까닭에 인공지능 신뢰성 평가가 이루어질 수 있는 조건으로서 투명성(transparency)과 책임성(accountability) 원칙이 한층 중요해진다. 인공지능 투명성은 인공지능 기업과 이용자 간 소통을 통해 신뢰 주체인 이용자가 판단을

강요 또는 기만당하지 않았다는 확신을 주는 과정으로,⁴⁶⁾ 이용자가 인공지능의 잠재적 영향과 인공지능 개발 과정에서 이루어진 주요 결정, 그것이 이용자에게 미치는 영향에 대한 정보를 제공받아야 함을 뜻한다.⁴⁷⁾ 투명성은 정보 제공을 통해 양 당사자를 커뮤니케이션과 논의의 장으로 끌어낸다. 반면 책임성은 행위자가 공론의 장에서 질문에 답하고 그 결과를 받아들이는 과정이다.⁴⁸⁾ 책임 있는 인공지능이란 이용자의 문의와 요청에 적극적으로 대응하는 것을 말한다. 질문에 답하고 반응하는 과정을 통해 인공지능을 믿을 수 있는지 판단할 수 있게 되므로 이 과정은 인공지능에 대한 신뢰를 구축하는 데 필수적이다.⁴⁹⁾ 결국 신뢰 형성에 중요한 것은 인공지능의 신뢰성 자체뿐 아니라 담론과 소통을 통해 신뢰성을 평가하는 과정이라는 점에서 인공지능 신뢰 정책에 관한 연구는 이러한 과정에 대한 고려를 포괄해야 할 것이다.

이용자들에게 충분한 정보가 제공된다면 신뢰 대상의 신뢰성을 평가할 수 있는 환경은 마련되었다고 할 수 있다. 그러나 특정 인공지능과 관련된 동일 정보가 제공되어도 각 이용자는 인공지능의 신뢰성을 서로 다르게 평가할 수 있다. 즉 신뢰 대상의 성능, 목적, 절차에 대한 신뢰 주체의 평가는 다양한 변수

2016; Ehsan Toreini/Mhairi Aitken/Kovila Coopamootoo/Karen Elliott/Carlos Gonzalez Zelaya/Aad van Moorsel, "The Relationship between Trust in AI and Trustworthy Machine Learning Technologies", 『Proceedings of the 2020 ACM Conference on Fairness, Accountability, and Transparency』, 2020.

- 43) 신뢰의 구성 요소 중 성능(performance)은 신뢰 주체가 기대한 업무를 성공적으로 수행할 수 있는 역량을 갖추고 있는지의 여부를 의미한다. 신뢰성의 두 번째 구성요소인 목적(purpose)은 신뢰 대상이 신뢰 주체의 이익과 복지를 염려하는 정도로 나타난다. 만일 신뢰 대상이 선의를 가지고 있지 않다면, 그는 악의를 가지고 또는 무심하게 신뢰 주체의 이익에 반하는 행동을 할 수 있다. 마지막으로 절차(process)는 신뢰 주체가 중시하는 원칙들을 신뢰 대상이 존중하고 따르는지 여부를 지칭한다. 신뢰 대상이 능력과 선의를 갖추고 있다 하더라도 신뢰 주체에게 중요한 원칙들을 준수하지 않는다면 그를 신뢰하기는 어렵다. John D. Lee/Katrina A. See, "Trust in Automation: Designing for Appropriate Reliance", 『Human Factors』, Vol. 46, No. 1, Human Factors and Ergonomics Society, 58-61면.
- 44) Rongbin Yang/Santos Wibowo, "User Trust in Artificial Intelligence: A Comprehensive Conceptual Framework", 『Electronic Markets』, Vol. 32, No. 4, Springer Science+Business Media, 2022, 2057면.
- 45) Warren J. von Eschenbach, "Transparency and the Black Box Problem: Why We Do Not Trust AI", 『Philosophy & Technology』, Vol 34, Springer Science+Business Media, 2021.

46) Heike Felzmann/Eduard Fosch Villaronga/Christoph Lutz/Aurelia Tamò-Larrieux, "Transparency You Can Trust: Transparency Requirements for Artificial Intelligence between Legal Norms and Contextual Concerns", 『Big Data & Society』, Vol. 6, No. 1, Sage, 2019, 9면.

47) Karl de Fine Licht/Jenny de Fine Licht, "Artificial Intelligence, Transparency, and Public Decision-making: Why Explanations are Key When Trying to Produce Perceived Legitimacy", 『AI & Society』, Vol. 35, Springer Science+Business Media, 2020; Gloria Andrada/Robert W. Clowes/Paul R. Smart, "Varieties of Transparency: Exploring Agency within AI Systems", 『AI & society』, Vol. 38, Springer Science+Business Media, 2023.

48) Maranke Wieringa, "What to Account for When Accounting for Algorithms: a Systematic Literature Review on Algorithmic Accountability", 『Proceedings of the 2020 ACM Conference on Fairness, Accountability, and Transparency』, 2020.


49) Heike Felzmann/Eduard Fosch-Villaronga/Christoph Lutz/Aurelia Tamò-Larrieux, "Towards Transparency by Design for Artificial Intelligence", 『Science and Engineering Ethics』, Vol. 26, Springer Science+Business Media, 2020; Maranke Wieringa, 앞의 글.

들에 의해 영향을 받는다. Dietz & Den Hartog은 신뢰 평가에 영향을 미치는 변수들을 개별 신뢰 주체와 신뢰 대상의 특성, 신뢰 주체와 신뢰 대상 간의 관계, 제도적 환경, 과업의 특성으로 유형화하였다.⁵⁰⁾ 우선, 개인적 성향, 인구통계학적 특성, 문화적 규범, 정치적 성향과 같은 신뢰 주체의 개인적 속성들이 신뢰 형성의 과정에 영향을 미칠 수 있다. 신뢰 대상의 속성이란 그의 지위나 과거 행동 등을 의미한다. 예를 들어 비슷한 업무에 사용되는 비슷한 성능의 인공지능 모델이라고 하더라도 중앙 정부가 활용할 때와 지방 정부가 활용할 때 시민들은 그동안의 인식이나 경험을 통해 그 신뢰성을 다르게 평가할 수 있다.⁵¹⁾ 관계 변수는 신뢰 주체와 신뢰 대상 간의 관계, 예를 들어 직장 내에서의 관계 양상, 동일시하는 정도, 상호작용을 한 기간, 유대감 등을 의미하고, 이에 따라 신뢰성에 대한 평가가 달라질 수 있다.⁵²⁾ 제도적 환경은 제재, 인센티브, 법적 규제, 행동 강령 등 인공지능을 둘러싼 거시적 환경을 의미한다. 마지막으로 과업의 특성 또한 신뢰성 평가에 영향을 미친다. 신뢰 주체는 특정 업무에 한하여 신뢰 대상을 신뢰할 수 있는데, 예를 들어 영어-한국어 번역에는 특정 인공지능을 신뢰할 수 있지만 영어-중국어 번역에는 신뢰하지 않을 수 있다.

이처럼 신뢰 주체인 이용자는 자신의 특성, 신뢰 대상인 인공지능과의 관계, 처해 있는 제도적 환경, 달성하려는 과업의 내용 등에 따라 신뢰성 평가를 달리 내릴 수 있다. 즉 동일한 신뢰성을 가진 인공지능이라고 할지라도 모든 이용자가 해당 인공지능과의 관계에서 위험을 감수하겠다고 판단하는 것은 아니다. 반대로 신뢰성 없는 인공지능을 이용자가 지식

의 부족으로 인해, 또는 다른 환경적, 맥락적 요소에 의해 신뢰하게 되는 경우가 생길 수 있다는 우려도 있다.⁵³⁾ 인공지능 신뢰 관련 정책 수립에 있어 신뢰 형성 과정에 관심을 가져야 하는 이유다.

신뢰 형성 과정에서 이용자는 인공지능의 신뢰성과 관련된 정보에 접근하고 자율적으로 그 신뢰성을 평가할 수 있어야 한다. 다른 한편, 인공지능도 이용자와의 소통을 통해 이용자에게 대한 정보를 제공받아야만 자신의 신뢰성을 증진할 수 있다. 이용자의 관점에서 인공지능은 블랙박스이나, 인공지능 시스템에게 이용자의 선호나 경험, 가치 등은 또 다른 블랙박스일 수 있다. 따라서 인공지능이 신뢰성을 높이기 위해서는 이용자의 필요, 이해관계, 가치관에 대한 정보를 확인하는 과정이 필요하다. 이용자와 이해관계자들의 목적과 가치 등에 대해서 파악하고 그 내용에 반응하는 조정(alignment) 과정은 인공지능에 대한 신뢰 형성에 매우 중요한 역할을 한다.⁵⁴⁾ 결국 신뢰 형성 과정은 신뢰 주체와 신뢰 대상 간의 쌍방향 커뮤니케이션과 소통이 핵심을 이룬다. 이러한 사실은 이후 인공지능 정책을 유형화하는 데에도 중요한 기준이 될 것이다. 지금까지의 논의를 종합하여 [그림 1]과 같이 신뢰에 대한 개념적 틀을 도출하였다. 신뢰는 이러한 복잡한 과정의 결과로써 나타나는 것이다. 다음 장에서는 이러한 개념적 틀을 바탕으로 인공지능에 대한 신뢰 정책을 유형화해보고자 한다.



[그림 1] 인공지능 신뢰의 개념적 틀

50) Graham Dietz/Deanne N. Den Hartog, 앞의 글, 564면.

51) Kaylyn Jackson Schiff/Daniel S. Schiff/Ian T. Adams/Joshua McCrain/Scott M. Mourtgos, "Institutional Factors Driving Citizen Perceptions of AI in Government: Evidence from a Survey Experiment on Policing", 『Public Administration Review』, American Society for Public Administration, 2023.

52) 박통희, 앞의 글, 7-8면; 상호작용의 기간이 길어짐에 따라 신뢰성의 세 요소의 중요도 변화에 대해서는 Stephen L. Jones/Priti Pradhan Shah, 앞의 글.

53) 신뢰할 수 있는(trustworthy) 대상을 신뢰하는 상태를 바람직하다고 보고 일반인(laypeople)이 신뢰할 수 없는 대상을 맹목에 의해 또는 오인하여 신뢰할 우려에 대해서는 Johann Laux/Sandra Wachter/Brent Mittelstadt, 앞의 글.

54) Iason Gabriel, "Artificial Intelligence, Values, and Alignment", 『Minds and Machines』, Vol. 30. No. 3, Springer Science+Business Media, 2020.

Ⅲ. 인공지능 신뢰 정책의 유형화

1. 정책의 필요성과 역할

인공지능 정책의 목표 중 하나는 이용자의 인공지능에 대한 의심(mistrust)⁵⁵⁾을 예방하는 것이다. 인공지능의 복잡성과 불투명성 때문에 이용자가 인공지능을 감시하고 의심해야 하는 불편을 겪게 될 수 있으므로,⁵⁶⁾ 이를 해결함으로써 사회적 비용을 줄여야 한다는 정책적 개입의 필요성이 제기된다. 의심은 이용자가 인공지능의 신뢰성을 충분히 평가하지 못한 결과이기도 하다.⁵⁷⁾ 기술의 신뢰성에 대한 판단은 신뢰 형성에 큰 영향을 미치는데, 일반 이용자에게는 기술의 신뢰성에 대한 충분한 정보가 없을 뿐 아니라 이를 평가할 수 있는 자원으로 제한되어 있다. 나아가 기술의 새로움으로 인해 자신이 위험에 노출되어 있다는 사실을 이용자는 아예 알지 못할 수도 있다. 이러한 환경에서 이용자의 신뢰 수준과 인공지능의 실제 신뢰성은 일치하지 않을 수 있다. 이용자가 인공지능의 실제 신뢰성만큼 인공지능을 신뢰하지 않는다면 인공지능은 기대보다 덜 수용될 것이고, 이는 사회적 효용을 낮춘다. 반대로 이용자가 인공지능의 실제 신뢰성보다 더 많이 신뢰한다면 이용자는 자신이 인지하지도 못하는 위험에 직접적으로 노출될 수 있다. 이용자는 인공지능의 신뢰성을 오류 없이 평가하여 신뢰할만한 것을 신뢰하고, 신뢰할 수 없는 것에 대한 신뢰는 철회할 수 있어야 한다. 신뢰할 수

없는 대상을 신뢰해서는 안 되기 때문이다.⁵⁸⁾ 그러므로 인공지능 신뢰 정책의 목적은 신뢰를 무조건 장려하는 것이 아니라 이용자가 인공지능의 신뢰성을 평가할 수 있는 환경을 조성하는 데 있다.

인공지능에 대한 신뢰성 평가에는 전문가, 정책 설계자와 같은 제3자의 의견이 중요하게 작동한다. 제3자의 의견은 이용자가 인공지능 신뢰성을 평가하는 데서 오는 인지적 부담을 줄인다. 신뢰성을 평가할 충분한 정보가 없는 이용자의 입장에서는 다른 사람의 신뢰성 평가에 의존하는 것이 효율적이다.⁵⁹⁾ 특히 정책 설계자는 인공지능 신뢰성에 대해 더 많은 정보를 가지고 있으며 인공지능이 어떻게 설계, 개발, 배포되어야 하는지 원칙을 제시할 수 있는 권한까지 가지고 있으리라 기대되는 행위자이다. 정책 설계자는 신뢰 대상의 신뢰성을 보다 정확하게, 보다 적은 인지적 자원으로 평가할 수 있는 환경을 조성하고 신뢰 주체가 대상을 어느 정도로 신뢰할 수 있는지 신호할 수 있는 중요한 행위자다.⁶⁰⁾

때로 정책 설계자는 인공지능의 신뢰성에 대한 보증을 제공하기도 한다. 이때 보증은 인공지능의 위험이 완전히 제거되었음을 의미하지 않는다. 위험이 없는(risk-free) 인공지능을 요구하는 것은 혁신을 저해할 우려가 있을 뿐 아니라 비현실적이다. 인공지능은 그 위험이 구체화하지 않았고 위험 관리에는 한정적인 자원이 활용되기 때문에 위험을 완전히 제거할 수 없다.⁶¹⁾ 그렇다고 인공지능의 위험이 신뢰 정책에서 고려되지 않아야 하는 것은 아니다. 오히려 현재

55) 신뢰와 대조되는 개념인 mistrust와 distrust 역시 한국에서는 모두 '불신'으로 번역되지만, 이론적으로 이 둘은 서로 다른 의미를 지닌다. mistrust는 신뢰 대상의 신뢰성에 대한 믿음이 형성되지 않아 신뢰 대상의 신뢰성에 대한 평가를 반복하는 점검 상태를 뜻한다. 반면 distrust는 신뢰 대상을 신뢰할 수 없다고 판단한 상태이다. 즉 distrust는 상대방이 다른 사람의 복지나 안전을 해치는 등 부정적인 행동을 할 것이라는 적극적인 예상으로, 종종 냉소나 경계심 등의 감정을 동반한다. 이수영/이하영, 앞의 책, 28면; Will Jennings/Gerry Stoker/Viktor Valgarðsson/Daniel Devine/Jennifer Gaskell, "How Trust, Mistrust and Distrust Shape the Governance of the COVID-19 Crisis", 『Journal of European Public Policy』, Vol. 28, No. 8, Taylor & Francis, 2021, 1176-1178면.

56) Will Jennings/Gerry Stoker/Viktor Valgarðsson/Daniel Devine/Jennifer Gaskell, 앞의 글.

57) 위의 글.

58) Onora O'Neill은 신뢰를 촉진하는 것보다 더 중요한 것은 무엇을 신뢰할 것인지의 문제이며, 그러한 까닭에 신뢰보다 신뢰성이 더 중요한 문제라고 역설한다. Onora O'Neill, "Trust and Accountability in a Digital Age", 『Philosophy』, Vol. 95, No. 1, Cambridge University Press, 2020, 4-6면 참조.

59) Johann Laux/Sandra Wachter/Brent Mittelstadt, 앞의 글, 17면; Warren J. von Eschenbach, 앞의 글, 1617면 참조.

60) Claire Hill/Erin O'Hara, "A Cognitive Theory of Trust", 『Washington University Law Review』, Vol. 87, No. 7, Washington University School of Law, 2006; Johann Laux/Sandra Wachter/Brent Mittelstadt, 앞의 글; Aurelia Tamò-Larrieux/Clement Guitton/Simon Mayer/Christoph Lutz, "Regulating for Trust: Can Law Establish Trust in Artificial Intelligence?", 『Regulation & Governance』, Vol. 18, No. 3, John Wiley & Sons, 2024.

61) 남구현, 앞의 글, 183-184면.


인공지능 정책은 위험 평가에 기반한 접근을 주요 방식으로 택하고 있다. 위험의 강도와 중대성에 따라 다른 규제 방식을 적용하는 것은 합리적인 시도다. 그러나 위험의 제거가 곧 신뢰 형성을 의미하지는 않으며, 따라서 이용자가 인공지능에 대한 신뢰를 형성하는 과정, 즉 인공지능의 신뢰성에 대한 평가 과정을 고려해야 한다.

정책 설계자는 이용자의 신뢰에 직접 개입할 수는 없다. 신뢰는 이용자의 자율적으로 판단한 결과이지 강제될 수 없기 때문이다. 반면 정책 설계자는 인공지능의 위험과 신뢰성에 개입할 수 있다. 정책 설계자는 인공지능이 초래할 위험을 관리하거나 신뢰성을 제고할 수 있는 환경을 만들기 위한 정책적 개입을 고려할 수 있는 것이다. 본 연구에서는 인공지능의 신뢰성과 리스크, 두 가치를 적용하여 인공지능 신뢰 정책을 유형화하고자 한다.

2. 위험과 신뢰성에 기반한 인공지능 신뢰에 대한 정책적 접근방법 비교

위험과 신뢰성의 관계를 살펴본다면, 인공지능의 리스크에 대한 인식과 요구되는 신뢰성 간에는 어느 정도 정(+)의 상관관계가 있다고 가정할 수 있다. 즉 특정 인공지능의 위험이 크면 신뢰성 역시 더 많이 요구된다. 위험하다고 판단되는 인공지능일수록 더 높은 신뢰성이 요구되는 것이다. 앞서 신뢰의 정의에서 위험이 신뢰의 전제 조건임을 보았다. 이용자들은 특정 인공지능을 신뢰할 수 있는지 판단하기 위해서 그 인공지능이 위험에 상응하는 수준의 신뢰성을 갖추었는지 알아보려 한다. 아래 [그림 2]는 특정 작업을 수행하도록 설계된 인공지능에 대해 이용자들이 인식하는 위험과 요구되는 신뢰성 사이의 관계를 나타낸다. 인공지능의 종류나 이용자의 개별 속성과 환경에 따라 그래프는 다양하게 나타날 수 있다.⁶²⁾ 가상의 인공지능이 갖는 위험과 신뢰성은 점 T로 그래

프 위에 표현될 수 있다. 위험이 완전히 제거될 수 없는 상황에서 이용자들은 노출될 수 있는 잠재적 위험에 상응하는 수준의 인공지능 신뢰성을 요구한다. 이상적 상황에서 신뢰성 있는 인공지능은 인식된 위험과 요구되는 신뢰성이 대등해지는, $y=x$ 선상에 위치할 것이다.



[그림 2] 인공지능의 위험 정도와 신뢰성 요구에 기반한 인공지능 신뢰에 대한 정책적 접근방법 비교

[그림 2]에서 확인할 수 있듯, 정책적 개입에 정당성을 부여하는 최소한의 위험 수준이 있을 것이며, 이에 정책적으로 금지되어야 하는 최고 수준의 위험 수준 또한 있을 수 있다. 그림 왼쪽에 위험이 a 미만인 인공지능이 존재하며, 이때 a는 정책 개입이 필요한 최소 수준을 뜻한다. 만약 위험 수준이 정책적 개입이 요청되는 최저 수준 미만이라면 기존 법률 외에 추가적인 규제를 부과하지 않는 것이 적절할 것이다. EU 인공지능 법이 저위험 인공지능 서비스가 기존 법률을 준수하는 한 추가 규제 없이 허용하는 것과 같다. 같은 논리로 위험 수준이 b보다 높은 인공지능들은 완전히 금지될 수 있다. b는 사회적으로 감당할 수 있는 위험의 상한으로서, 아무리 신뢰할 수 있다 하더라도 사회가 노출되어서는 안 되는 위험의 임계를 뜻한다.

정책적 개입이 필요한 대부분의 사례는 위험 수준이 a와 b 사이에 있는 인공지능들이다. [그림 2]에서

62) 본 그래프는 편의상 리스크와 신뢰성이 정비례하는 그래프로 표현되었지만, 상황에 따라 그 기울기나 모양은 다양하게 나타날 수 있을 것이다.

가상의 인공지능 T의 위험 x 는 a 와 b 사이에 있어서, 완전히 금지되지도 않으나 완전히 자유롭게 유통되도록 할 수도 없는 상황이다. 게다가 인공지능 T는 주어진 위험 수준을 고려할 때 요구되는 수준의 신뢰성을 갖추고 있지 못해 교정이 필요하다. 이런 경우 정책 설계자는 위험 또는 신뢰성에 대한 개입을 계획할 수 있다.

정책적으로 인공지능 T의 위험을 기존의 값 x 에서 x' 로 줄이는 것(T1으로 움직이는 것)을 목표로 하는 것을 ‘위험 축소 접근’이라 할 수 있다. 정책 설계자를 비롯한 전문가가 인공지능의 위험을 사전에 감지하고 이를 관리하고 그 결과를 안내하는 과정을 거치는 것이다. 위험 축소가 성공적으로 이루어진다면, 인공지능 T1은 그 신뢰성에 상응하는 수준의 위험을 지니게 된다. 이러한 접근은 인공지능의 신뢰성을 높이는 것보다는 현재의 물리적, 재정적, 환경적 위험을 즉시 낮추는 데 주안점을 둔다. 예를 들어 정책 설계자는 안전성, 강건성, 개인정보보호, 공정성과 같은 목표를 설정하고 이를 달성하지 못한 인공지능에 제재를 가할 수 있다. 위험 축소 접근에서 정책 설계자는 목표와 기준을 정하고 이를 평가할 수 있는 외부 기관을 지정하는 등의 역할을 수행한다. 위험 축소 접근은 긴박한 위험에 대처해야 할 때 효과적일 수 있다는 장점이 있다. 그러나 정책 설계자들이 인공지능과 관련된 모든 잠재적 위험과 그 해결책을 알고 있으며 이를 성공적으로 집행할 수 있다고 가정하는 것은 비현실적일 수 있다.⁶³⁾ 또한 자칫 기술의 창의적인 발전 가능성이 저해되거나 기업이 자신의 역할을 정책 설계자가 제시하는 원칙을 수동적으로 따르는 것으로 한정해버릴 우려 또한 존재한다.

한편 ‘신뢰성 향상 접근’은 인공지능 T의 신뢰성을 y 에서 y' 로 높이는 데(T2로 움직이는 데) 주안점을 두고 인공지능이 그 위험 수준이 요구하는 정도로 신뢰성을 개선할 수 있도록 독려한다. 신뢰성 향상 접근은 인공지능 기술과 기업들이 그들의 성능, 목적, 절차를 개선하도록 함으로써 인공지능의 신뢰성을

향상하고자 한다. 신뢰성 향상 접근은 위험 축소 접근보다 더 오랜 시간이 걸릴 수 있지만, 정책 설계자들이 알지 못하거나 직접 규제할 수 없는 위험까지 다룰 수 있는 잠재력이 있고, 인공지능이 보다 자발적으로 신뢰성을 높이도록 독려할 수 있다는 장점이 있다. [표 1]은 지금까지 논의한 정책 설계자의 인공지능 신뢰에 대한 접근방법을 정리한 것이다.

전략	상황	대응
추가 규제 없음	인공지능으로 인해 발생할 것으로 예상되는 위험이 정책 개입 필요 수준 이하인 경우	기존 법률 외에 추가적인 규제가 필요하지 않음
금지	인공지능으로 인해 발생할 것으로 예상되는 위험이 허용 가능한 위험 수준을 초과하는 경우	인공지능의 설계, 개발, 배포가 금지됨
위험 축소	인공지능으로 인해 발생할 것으로 예상되는 위험이 허용 가능한 범위 내에 있지만 그 신뢰성이 위험 수준에 미치지 못한 경우	정책 설계자는 인공지능의 위험 수준을 줄여 균형을 달성하고자 함
신뢰성 향상	인공지능으로 인해 발생할 것으로 예상되는 위험이 허용 가능한 범위 내에 있지만 그 신뢰성이 위험 수준에 미치지 못한 경우	정책 설계자는 인공지능의 신뢰성을 높여 균형을 달성하고자 함

[표 1] 인공지능 신뢰 정책의 접근방법

3. 인공지능 신뢰의 대상

지금까지의 논의를 토대로 인공지능 신뢰 정책을 유형화하기에 앞서, 인공지능 신뢰의 대상이 무엇인지 먼저 논의하고자 한다. 일반적으로 “인공지능을 신뢰한다”고 할 때 신뢰의 대상은 무엇인가? 기술에 대한 신뢰는 여러 대상의 신뢰성을 종합적으로 평가한 결과일 수 있다.⁶⁴⁾ 자동차 구매를 결정할 때 소비

63) Aurelia Tamo-Larrieux/Clement Guillon/Simon Mayer/Christoph Lutz, 앞의 글, 781면.

64) John D. Lee/Katrina A. See, 앞의 글, 58면; Carmen Iuliana Mal/Gary Davies/Audra Diers-Lawson, “Through the Looking Glass: The Factors That Influence Consumer Trust and Distrust in Brands”, 『Psychology & Marketing』, Vol. 35, No. 3, John Wiley & Sons, 2018; Matthias Söllner/Axel

자는 자동차의 각 부품의 신뢰성을 일일이 평가할 수도 없고 평가할 필요도 없다. 자동차 기업을 신뢰할 수 있는지 여부를 결정할 뿐이다. 마찬가지로 인공지능의 편향성이 널리 알려진 환경에서, 사회적 소수집단에 속한 이용자는 자신의 입장을 잘 대변하는 기업의 인공지능을 더 신뢰할 수 있다.⁶⁵⁾ Andras 등 (2018)은 기계에 대한 다층적 신뢰를 구분하여 기계 자체에 대한 신뢰를 1차 신뢰로, 제공자에 대한 신뢰를 2차 신뢰로 개념화한다.⁶⁶⁾ 1차 신뢰가 기술의 신뢰성을 평가하고 인간과 기계의 상호작용에 초점을 맞추는 반면, 2차 신뢰는 인공지능 생태계 전반으로 신뢰의 대상을 확장한다.⁶⁷⁾ 따라서 인공지능과 같은 기술의 신뢰 형성 과정을 분석을 위해서는 기술 자체에 대한 분석뿐만 아니라 인공지능 기업까지 종합적으로 고려해야 한다는 것이다.⁶⁸⁾ 인공지능의 불투명성으로 인해 이용자는 인공지능으로 인한 직간접적인 영향을 온전히 이해하기 어렵다. 설명 가능한 인공지능을 구현하기 위한 다양한 기술적 노력이 이루어지고 있지만, 아직 인간이 인공지능의 생성 과정을 완전히 이해할 수 있는 단계에 이르지 못했다. 인공지능 기업은 인공지능에 실질적인 영향을 미치는 행위자이며, 이용자는 인공지능의 신뢰성을 평가할 때 인공지능 기술과 기업을 종합적으로 고려한다.

그동안의 경험적 연구들도 기술 신뢰의 대상이 기술 자체뿐 아니라 기업에까지 확장됨을 시사한다. Söllner et. al.은 다양한 행위자에 대한 신뢰가 이용자로서 하여금 정보 서비스에 대한 신뢰, 나아가 수용

여부에 영향을 미칠 것이라는 아이디어를 바탕으로 기술 수용 모델(Technology Acceptance Model, TAM)을 확장했다.⁶⁹⁾ 이들은 정보 서비스에 대한 신뢰에 서비스 제공자, 인터넷 사용자 커뮤니티, 인터넷 인프라에 대한 신뢰가 영향을 미친다는 신뢰의 네트워크를 제안하고, 실험 연구를 통해 신뢰 네트워크의 행위자 중 정보 서비스 제공자가 정보 시스템에 대한 신뢰에 유의미한 영향을 미친다는 사실을 밝혔다.⁷⁰⁾ 이용자 대상 심층 인터뷰를 기반으로 한 연구에서도 제품의 신뢰도를 평가할 때 제품을 제공하는 기업의 신뢰도가 중요하다는 사실이 확인되었다.⁷¹⁾ 이러한 연구들은 제품에 실질적인 영향력을 행사하는 기업에 대한 신뢰가 인공지능 신뢰에 상당한 영향을 미칠 수 있음을 시사한다. 즉 이용자는 인공지능 기술 자체뿐만 아니라 기술을 설계, 개발, 배포한 기업의 신뢰성도 종합적으로 평가할 것이다. 인공지능 신뢰의 대상으로 기술에만 초점을 맞추어서는 이러한 종합적인 평가 과정을 포착할 수 없다. 인공지능의 신뢰성을 평가하기 위해서는 기술과 그 제공 기업을 종합적으로 고려하는 다층적(multi-layered) 분석이 필요한 것이다. 본 연구에서는 인공지능 신뢰 정책을 인공지능 기술에 대한 신뢰와 인공지능 기업에 대한 신뢰에 대한 것으로 나누어서 유형화해보고자 한다.

4. 인공지능 신뢰 정책의 유형화

지금까지의 논의를 토대로 인공지능 신뢰 정책의 유형을 분류하는 두 가지 차원을 도출할 수 있다. 첫 번째 차원은 ‘접근방법’이다. 정책 설계자들은 위험 축소 또는 신뢰성 향상의 서로 다른 두 접근방법에 기반하여 정책을 설계할 수 있다. 두 번째 차원은 ‘신뢰 대상’이다. 인공지능 기술과 기업이 인공지능 신뢰 정책의 대상이 될 수 있다. 이들 두 가지 차원을 통해 인공지능 신뢰 정책의 네 가지 유형을 [표 2]와

Hoffmann/Jan Marco Leimeister, "Why Different Trust Relationships Matter for Information Systems Users", 『European Journal of Information Systems』, Vol. 25, Taylor & Francis, 2016.

65) Alon Jacovi/Ana Marasović/Tim Miller/Yoav Goldberg, "Formalizing Trust in Artificial Intelligence: Prerequisites, Causes and Goals of Human Trust in AI", 『Proceedings of the 2021 ACM Conference on Fairness, Accountability, and Transparency』, 2021, 632면.

66) Peter Andras et al., 앞의 글, 80면.

67) 위의 글. 물론 인공지능과 인공지능 기업에 대한 평가는 각각 이루어지면서도 서로 영향을 미친다.

68) Peter Andras et al., 앞의 글; Keng Siau/Weiyu Wang, "Building Trust in Artificial Intelligence, Machine Learning, and Robotics", 『Cutter Business Technology Journal』, Vol. 31, Cutter Consortium, 2018.

69) Matthias Söllner/Axel Hoffmann/Jan Marco Leimeister, 앞의 글.

70) 위의 글, 280면 이하 참조.

71) Carmen Iuliana Mal/Gary Davies/Audra Diers-Lawson, 앞의 글.

같이 도출하였다.

위험 축소 접근방법은 신뢰의 대상이 인공지능 기술인지, 인공지능 기업인지에 따라 강화 정책과 준수 정책으로 유형화된다. 정책 설계자들은 인공지능 기술의 위험 수준을 낮추기 위해 따라야 하는 공학적 기준을 설정하거나, 기업이 인공지능을 어떻게 설계, 개발, 배포해야 하는지에 대한 원칙을 제시할 수 있다. 전자는 ‘강화’ 정책으로, 후자는 ‘준수’ 정책으로 명명한다. 강화 정책은 이용자가 감당해야 하는 위험의 수준을 축소하기 위한 기술적 조치에 주목한다. 인공지능의 위험을 평가할 수 있는 데이터셋 및 도구 등 자원을 제공하는 정책적 조치에서부터 기술 개발 가이드라인 제공, 표준화, 라이선스 제도 등 정부가 공인한 기술 방침을 따르도록 주문하는 것까지 다양한 정책적 수단이 동원될 수 있다. 반면 준수 정책은 기업의 인공지능 시스템 개발 과정에 주목한다. 설계, 개발, 배포 과정에서 기업이 고려해야 하는 사항들을 규정 또는 가이드라인 등의 형식으로 지도하는 것이 가장 대표적인 준수 정책이라 할 수 있다. 의사결정 과정을 문서화하도록 하여 책임 소재가 불분명해지지 않도록 관리할 것을 권고하거나 문제 발생을 대비해 구제수단을 마련해 두도록 제안하는 등 인공지능을 설계, 개발, 배포하는 과정에서 기업 내부에서 발생할 수 있는 위험을 줄이기 위한 다양한 조치들이 포함될 수 있다. 개인정보 유출 위험을 예로 들어볼 때 개인정보가 기술적 측면에서 얼마나 강력한 보호 수준을 갖추어 처리되는지에 중점을 두는 경우를 강화 정책이라 할 수 있고, 개인정보의 수집과 저장, 처리에 관한 조직의 주요 결정을 문서화하고 이용자 데이터에 접근 가능한 내부 직원을 한정하는 정책을 수립하도록 권하는 경우는 준수 정책에 해당한다.

한편 신뢰성 향상 접근방법은 인공지능 기술과 기업에 대한 신뢰성을 높이하고자 한다. 인공지능 기술의 신뢰성을 높이기 위해 정책 설계자들은 인공지능 기술의 성능, 목적, 절차와 관련된 정보를 이용자가 알기 쉽게 제시하도록 한다. 이를 ‘설명’ 정책으로 명명한다. 설명 가능한 인공지능 개발을 독려하거나 기술의 투명성을 높이도록 요구하는 원칙들이 대표적인

		접근방법	
		위험 축소 (risk reduction)	신뢰성 향상 (trustworthiness building)
신뢰 대상	인공 지능 기술	강화(enhanced) 인공지능의 위험을 완화하기 위한 기술 및 공학적 원칙을 권장 예시) 정확성, 강건성, 개인정보보호 강화 기술	설명(explanatory) 인공지능의 신뢰성 향상을 위해 이용자와의 기술적, 공학적 주요 사안에 대한 설명 권장 예시) 기술적 투명성 및 설명 가능성
	인공 지능 기업	준수(complying) 인공지능의 위험을 완화하기 위해 기업이 준수해야 하는 설계, 개발, 배포 과정에 대한 원칙을 권장 예시) 문서화, 인간의 감독, 사내 데이터 정책	참여(participatory) 인공지능의 신뢰성 향상을 위해 이용자와 인공지능 설계, 개발, 배포 과정상 주요 사안에 대한 의사소통 권장 예시) 이해관계자 참여, 기업 의사결정 설명 가능성

[표 2] 인공지능 신뢰 정책 유형

사례다. 설명 정책은 이용자가 인공지능과 상호작용한다는 사실을 알고, 기술의 신뢰성을 평가할 수 있도록 돕는다. 알고리즘의 학습 데이터와 사용 모델에 대한 정보부터 모델이 저장, 업데이트되는 내용에 이르기까지 다양한 정보를 제공하도록 할 수 있다.⁷²⁾

72) 인공지능 기술의 투명성이 어떤 정보를 제공하는 것을 의미하는지에 대해 다양한 연구들이 진행되고 있다. Andradá et. al. (2023)은 알고리즘 투명성이 제공할 수 있는 정보의 유형으로 알고리즘 자체에 대한 정보(정보 투명성), 알고리즘 개발이 환경과 노동에 미치는 영향에 대한 정보(물질 투명성), 알고리즘이 인간 인지에 미치는 영향에 대한 정보(전환 투명성)의 세 종류로 유형화한다. 이와 달리 전 세계 파운데이션 인공지능 모델의 투명성 지표를 제시한 Rishi Bommasani et. al., (2023)은 투명성을 ① 데이터의 구성, 데이터 가공 절차, 데이터 가공에 투입된 노동과 그 지리적 분포, 모델의 학습 방법, 에너지 사용, 저작권 및 개인 정보 침해 우려 등을 안내하는 업스트림 투명성, ② 모델의 성능 평가와 모델의 크기, 구조, 한계와 위험, 잠재적 편향과 악의적 이용 가능성, 평가의 신뢰 가능성 등에 대한 정보를 제공하는 모델 투명성, ③ 배포 채널, 특정 이용 패턴 또는 이용자에 대한 제

한편, 정책 설계자들은 인공지능 기업이 이해관계자들과 상호작용하여 위험을 발견하고 그들의 필요와 가치를 파악하도록 장려할 수 있다. 이를 ‘참여’ 정책이라 부르기로 한다. 참여 정책은 인공지능의 설계, 개발, 배포에 실질적인 영향을 미치고 있는 행위자들의 신뢰성을 이용자들이 평가하고 나아가 직접 의사결정 과정에 참여할 수 있는 환경을 조성하고자 한다. 이로써 이용자가 기술 자체만이 아니라 관련 제품을 제작하는 시스템 전반의 신뢰성을 평가할 수 있도록 돕는다.⁷³⁾ 예를 들어 정책 설계자들은 기업의 주요 의사결정이 이해관계자들의 감독을 받도록 하는 제도적 환경을 설계하거나, 이용자와 기업 간의 교류 및 상호학습을 촉진하기 위한 의사결정 과정 개선을 권장할 수 있다.⁷⁴⁾

인공지능 신뢰 정책 접근방법과 대상이라는 두 차원은 이론적으로 정책 설계자들이 인공지능 기술 또는 기업의 위험을 줄이거나 신뢰성을 높이기 위해 선택할 수 있는 네 가지 서로 다른 정책 유형이 가능함을 드러낸다. 물론 현실 정책은 여러 정책 유형이 혼합되어 만들어질 것이다. 그럼에도 불구하고 인공지능 신뢰 정책의 유형화 작업은 정책을 설계하고 기존 정책을 분석, 평가하는 데 유용한 도구가 될 수 있을 것이다.

V. 결론 및 정책적 함의

신뢰성 있는(trustworthy) 인공지능은 인공지능을

한, 모델에 의해 영향을 받을 것으로 예상되는 사람과 그 분포, 이용자 데이터의 저장과 공유, 모델 업데이트 정보 등의 다운로드 투명성으로 구분한다. Gloria Andrada/Robert W. Clowes/Paul R. Smart, 앞의 글; Rishi Bommasani, et. al. "The Foundation Model Transparency Index", arXiv preprint, 2023. 참조.

73) Warren J. von Eschenbach (2021)은 인공지능 투명성의 범위가 인공지능 기술 자체에 국한되어서는 안 되며, 인공지능이 개발되는 전체 시스템으로까지 확장되어야 한다고 주장한다. Warren J. von Eschenbach, 앞의 글.

74) 예를 들어 정책 설계자는 감사, 모니터링 등의 정책 수단을 활용해 신뢰와 관련된 정보를 제공하도록 독려할 수 있다. Claire Hill/Erin O'Hara, 앞의 글, 1758면; Aurelia Tamo-Larrieux/Clement Guitton/Simon Mayer/Christoph Lutz, 앞의 글, 783면.

수용할 수 있는 조건으로서 중요한 정책적 함의를 가지며, 인공지능 거버넌스의 중요한 축이 되어 왔다. 또한 인공지능 신뢰는 인공지능 관련 법률, 행정명령, 가이드라인 등의 주요 목표로 제시되고 있다. 그러나 인공지능 신뢰의 중요성에 대한 사회적 합의에도 불구하고 그 개념적 정의는 여전히 모호하다. 이에 본 논문은 인공지능 신뢰의 개념을 체계적으로 살펴보고, 이용자의 신뢰 형성 과정을 고려하여 정책 설계자가 취할 수 있는 인공지능 신뢰 정책 접근방법을 살펴본 후, 인공지능 신뢰 정책의 유형화를 통해 관련 정책의 분석과 설계를 위한 이론적, 실천적 시사점을 제공하고자 하였다.

본 연구는 이론적 검토를 통해 인공지능에 대한 신뢰를 ‘그것으로 인해 발생할 수 있는 위험에도 불구하고 인공지능을 이용하고 상호작용하겠다는 의지’로 정의하였다. 즉 위험은 신뢰의 전제 조건이고, 인지된 위험이 없으면 신뢰가 형성될 수 없다. 많은 인공지능 정책이 위험 축소에 초점을 맞추고 있으나, 실제 인공지능의 위험을 완전히 없애는 것은 비현실적인 목표일 뿐 아니라 자원의 비효율적인 배분을 초래할 수 있다.⁷⁵⁾ 본 연구가 제시하는 인공지능 신뢰의 정의는 정책 설계자들이 위험 축소에 힘쓰는 것 이상으로 인공지능과의 신뢰 구축 과정에 초점을 맞추어야 함을 드러낸다. 인공지능 신뢰는 이용자가 신뢰 대상인 인공지능 기술 및 기업의 신뢰성을 종합적으로 평가하여 잠정적으로 믿음을 형성하거나 믿음을 철회하는 능동적 평가 과정이다. 이러한 능동적, 내면적 평가 과정은 정부나 기업이 직접 개입할 수 없는 부분이다. 다만 이용자가 인공지능이 그 위험에 부합하는 수준의 신뢰성을 갖추고 있는지 확인하고자 할 때, 정책 설계자는 인공지능이 위험 수준에 상응하는 신뢰성을 갖추고 있는지 평가하고 필요한 경우 이를 신호할 수 있을 뿐이다.

정책적 개입의 필요성이 거론되는 대부분의 상황에서 정책 설계자는 인공지능의 위험 축소 또는 신뢰성 향상의 접근방법을 고려한다. 또한 신뢰 대상은

75) Aurelia Tamo-Larrieux/Clement Guitton/Simon Mayer/Christoph Lutz, 앞의 글, 781면.

인공지능 기술에 대한 신뢰와 기업에 대한 신뢰로 나누어질 수 있다. 본 연구에서는 이렇게 서로 다른 정책적 접근방법과 신뢰 대상을 고려하여 인공지능 신뢰 정책의 유형을 강화, 준수, 설명, 참여로 구분하였다. 강화 정책과 준수 정책은 위험 축소 접근에 근거한 것으로, 인공지능의 위험 수준을 줄이기 위한 기술적 조치들에 집중하거나, 기업의 인공지능 개발 과정에서 발생할 수 있는 위험 요소를 제거하고자 한다. 설명 정책과 참여 정책은 신뢰성 향상 접근에 근거하여 인공지능의 신뢰성을 평가하고 개선하는 과정에 초점을 맞추며, 인공지능 기술의 신뢰성과 관련된 정보를 이용자에게 제공하도록 독려하거나, 이용자가 인공지능 기업의 신뢰성을 평가하고 나아가 인공지능의 신뢰성에 영향을 미칠 수 있는 주요 의사 결정 과정에 참여할 수 있는 환경을 조성하고자 한다. 현재까지 세계 각국이 제안한 인공지능 신뢰성 향상을 위한 가이드라인 및 프레임워크는 이러한 네 유형의 인공지능 신뢰 정책을 담고 있으나 각기 다른 정책 유형에 주안점을 두고 있을 것으로 보인다. 향후 체계적인 분석을 통해 각국의 인공지능 정책 방안들을 고찰하고 평가하는 것은 매우 의미 있는 후속 연구가 될 것이다.

또한 인공지능 신뢰 정책의 접근방법과 정책 유형에 대한 본 연구는 역설적으로 인공지능 기업의 역할과 책임을 강조한다. 인공지능, 특히 딥러닝에 기반한 인공지능 모델의 판단 및 생성은 전문가조차 그 과정을 정확히 알기 어렵다. 그 결과 인공지능 기술 자체만을 대상으로 한 정책적 논의는 기술적 교착에 부딪히게 되고, 이는 인공지능 신뢰 정책 논의의 진전을 저해한다. 기업들도 자체적으로 인공지능 신뢰 향상을 위한 노력을 기울이고 있는데, 글로벌 빅테크 기업들은 신뢰할 수 있는 안전한 인공지능 개발에 필요한 통합 도구 및 기능들을 모은 툴킷(Responsible AI Toolkit)을 자체 개발하고 공개하고 있으며, 관련 시장 규모 또한 지속적으로 성장하고 있다.⁷⁶⁾ 또한 이용자는 인공지능 기술뿐 아니라 기업

의 신뢰성을 종합적으로 평가하여 인공지능의 위험을 받아들일지 여부를 결정한다. 따라서 인공지능 기업은 인공지능 신뢰의 대상이자 중요한 이해관계자이다. 앞으로의 인공지능 신뢰 정책 논의에서 기업의 실질적인 역할을 고려하고 독려하는 방안들이 더 활성화될 필요가 있다.

인공지능 신뢰의 개념적 틀과 정책적 접근방법, 그리고 이에 따른 정책 유형화를 시도한 본 연구의 결과들은 앞으로의 정책 방향에 많은 함의를 갖는다. 무엇보다도 인공지능 정책이 이용자가 노출될 수 있는 위험을 완화하려는 노력과 함께 위험에 비례하는 신뢰성을 구축할 수 있는 환경을 조성하는 데도 힘써야 한다는 점을 시사한다. 인공지능 신뢰의 의미와 형성 과정에 대한 이해가 불분명한 채 하향식 지침과 가이드라인, 체크리스트만 제시된다면 인공지능 기업은 자신의 역할을 정부 지침을 따르는 것으로 축소 해석할 수도 있고 그 과정에서 실효성 있는 신뢰성 향상이 이루어질 가능성은 매우 작아진다. 또한 인공지능의 신뢰성 향상이 실제 이용자들의 신뢰 향상으로까지 이어지려면 인공지능과 이용자 간의 투명하고 적극적인 소통이 필수적이다. 신뢰성 자체뿐 아니라 그에 대한 이용자들의 평가가 신뢰 형성으로 이어지기 때문이다. 앞에서 논의했듯이 신뢰가 형성되면 이용자들은 인공지능과 그 기업의 신뢰성 즉 인공지능이 무엇을 얼마나 잘할 수 있는지, 왜 그렇게 하는지, 어떤 원칙과 가치에 따라 행동하는지 알 수 있어야 한다. 인공지능 역시 이용자의 선호에 부합할 수 있도록 이해관계자들의 관점을 고려하는 검토 과정이 필요하다.⁷⁷⁾ 이렇게 신뢰성 향상 접근은 장기간에 걸친 투명한 의사소통, 책임 있는 상호작용으로 연결되어야 의미 있는 결과를 도출할 수 있는 것이다.⁷⁸⁾ 그러한 측면에서 인공지능 관련 정책이 탐다운

76) “안전·신뢰 AI”, 『KISTEP In』, Vol.48, 한국과학기술기획평가원(KISTEP), 구분진, 2024, 61면.

77) Denis Vetter, et. al., “Lessons Learned from Assessing Trustworthy AI in Practice”, 『Digital Society』, Vol. 2, No. 35, Springer Science+Business Media, 2023; Roberto V. Zicari, et. al., “Z-Inspection@: A Process to Assess Trustworthy AI”, 『IEEE Transactions on Technology and Society』, Vol 2, No. 2, IEEE, 2021.

78) Johann Laux/Sandra Wachter/Brent Mittelstadt, 앞의 글, 4면.

(top-down) 방식, 국가 주도의 가부장적(paternalistic) 방식, 기존의 법체제만을 이용한 방식이 아니라 다중 이해당사자주의(multistakeholderism)를 기반으로 한 거버넌스 방식의 논의로 진행되는 것은 매우 의의가 있는 일이다.

물론 인공지능에 직간접적으로 영향을 받는 이해관계자를 정의하고 이들의 참여를 독려하는 것은 매우 도전적인 과제다. 특히 각 이용자의 인공지능에 대한 이해도가 다른 상황에서 어려움이 발생할 수 있고, 이용자 개인이 처한 맥락에 맞추어 소통할 수 있는 능력 또한 요청된다. 비판적 이용자의 역할이 인공지능 거버넌스 논의 전반에서 강조되는 것도 이러한 이유에서다.⁷⁹⁾ 다시 말해서 이용자의 관심과 역량, 리터러시의 중요성은 아무리 강조해도 지나치지 않으며, 이용자를 ‘보호의 대상’으로뿐 아니라 ‘참여의 주체’로 보고 그 역할 강화를 위한 정책적 고려를 해나가는 것이 필요한 시점이다.⁸⁰⁾

본 연구의 후속 연구로서, 앞서 제안된 인공지능 정책 유형을 전 세계적으로 발표되고 제안되고 있는 다양한 신뢰 정책 및 가이드라인에 적용하여 분석하는 것은 의미 있는 작업이 될 것이다. 예를 들어 유럽 연합의 신뢰성 있는 인공지능을 위한 가이드라인과 미국의 위험관리 프레임워크를 비교해 보면 서로 비슷한 내용을 담고 있기도 하지만 미묘하게 상반되는 정책 방향을 강조하고 있기도 하다는 점에서 좋은

후속 연구 대상이다. 나아가 우리나라 등 인공지능 거버넌스에 관심을 두고 다양한 법제 및 가이드라인을 추구하고 있는 국가들의 여러 제안 및 기업들이 내부적으로 만들고 있거나 제안하는 신뢰 관련 정책들을 대상으로 체계적인 분석을 시도하는 것도 많은 시사점을 제공해 줄 수 있을 것이다. 또한 인공지능 신뢰 형성 모형을 더욱 정교하게 정립하고 실제 데이터를 활용한 경험적 검증을 해볼 필요도 있다. 인공지능 기술과 기업 각각의 신뢰성 평가가 어떻게 영향을 미치는지, 신뢰 주체와 신뢰 대상 간 관계적 특성이 이용자의 신뢰성 평가에 어떤 영향을 미치는지 등에 관한 많은 연구가 필요하다. 인공지능 신뢰 네트워크의 다양한 행위자들이 어떤 영향을 주고받는 지 역시 앞으로의 연구가 기대되는 분야 중 하나다. 본 논문은 이용자와 인공지능 기술 및 기업의 관계에 주목했으나, 앞으로 정부, 전문가, 여론 주도층, 오픈소스 커뮤니티 등 신뢰의 복잡한 네트워크를 포괄적으로 고려한 논의를 통해 각 행위자가 이용자들의 신뢰 형성에 미치는 영향에 대한 체계적 연구가 이어지기를 바란다.

〈참고문헌〉

〔단행본〕

- 이수영/이하영, 『정부신뢰 2요인론: 신뢰 요인과 불신 요인에 대한 탐색』, 서울대학교 행정대학원 한국행정연구소 연구문고 1, 윤성사, 2022
- 최경진/강지원/김법연/김형준/박신욱/오정인/채기현, 『EU 인공지능법』, 박영사, 2024.
- Reeves, B./Nass, C., 『The media equation: How people treat computers, television, and new media like real people and Places』, Cambridge University Press. 1996.

〔보고서〕

- 구본진, “안전·신뢰 AI”, 『KISTEP In』, Vol.48, 한국과학기술기획평가원(KISTEP), 2024, 60-69.

79) Kemper & Kolkman (2019)은 투명성이 그 자체만으로 인공지능에 대한 평가를 의미할 수 없으며, 비판적인 이용자가 존재하지 않는다면 인공지능의 투명성과 책임성은 실질적 의미를 갖기 어렵다는 사실을 지적한다. Jakko Kemper/Daan Kolkman, “Transparent to Whom? No Algorithmic Accountability without a Critical Audience”, 『Information, Communication & Society』, Vol. 22, No. 14, Routledge, 2019.

80) 윤혜선(2024)은 AI 혁신 및 발전의 주체는 이용자가 되어야 함을 역설하면서, 수동적 소비자에서 능동적 참여자로, 서비스 수용자에서 서비스 공동 설계자로, 단순 데이터 제공자에서 데이터 관리자 및 거버넌스 주체로 이용자가 변화하고 있으며 그에 따른 책임 역시 증가해야 함을 강조하였다. 윤혜선, 2024, 앞의 글; 이상욱(2024)도 집단과 분야에 따라 선호와 가치가 다를 수 있으며, 이러한 가치 간 긴장이 존재한다는 사실은 인공지능과 관련된 이해관계자들이 참여할 수 있는 사회적 조정 과정의 필요성을 역설하는 것이라고 하였다. 이상욱, “안전하고 신뢰가능한 AI를 위한 국제 거버넌스와 AI 리터러시”, 『D.E View』, Vol. 5, 한국인터넷기업협회 디지털경제연구원, 2024, 18면 이하 참조.

이상욱, “안전하고 신뢰가능한 AI를 위한 국제 거버넌스
스와 AI 리터러시”, 『D.E View』, 한국인터넷
기업협회 디지털경제연구원, 2024, 14-25.

[학술논문]

김태오, “사이버 안전의 공법적 기초 - 독일의 IT 기
본권과 사이버안전법을 중심으로”, 『행정법연
구』, 제45권, 행정법이론실무학회, 2016,
105-134.

남구현, “인공지능 규율에 있어 위험기반 접근 방식의
적합성 고찰”, 『법학논총』, 제36권 제1호,
2023, 159-192.

박통희, “신뢰의 개념에 대한 비판적 검토와 재구성”,
『한국행정학보』, 제33권 제2호, 한국행정학
회, 1999, 1-17.

선지원, “인공지능의 사회적 수용을 위한 국가법의
과제”, 『국가법연구』, 제16권 제3호, 한국국가
법학회, 2020. 39-65.

심준섭, “원자력 발전소에 대한 신뢰, 인식된 위험과
해택, 그리고 수용성”, 『한국정책학회보』, 제
18권 제4호, 한국정책학회, 2009, 93-132.

윤혜선, “리스크 규제에 관한 공법적 연구: 식품안전법
제를 중심으로”, 박사학위논문, 서울대학교,
2009.

윤혜선, “인공지능의 사회적 수용성과 법제도의 기능
적 관계에 관한 소고”, 『경제규제와 법』, 제14
권 제1호, 서울대학교 공익산업법센터, 2021.
32-56.

_____, “인공지능 거버넌스의 국제 동향과 한국의
좌표: 현황과 도전과제”, 서울대학교 공익산업
법센터 제24회 국제학술대회, 『인공지능의 시
대를 향한 규제 거버넌스의 모색』, 2024. 10. 3.

채원호/손호중, “정책실패와 신뢰”, 『한국행정논집』,
제17권 제1호, 한국정부학회, 2005, 1-28.

최태현, “거버넌스에 대한 가치 지향과 신뢰”, 『한국행
정학보』, 제49권 제2호, 한국행정학회, 2015.
1-24.

Andrada, G./Clowes, R. W./Smart, P. R., “Varieties
of transparency: Exploring agency within AI
systems”, 『AI & society』, Vol. 38 No. 4,
Springer Science+Business Media, 2023,
1321-1331.

Andras, P./Esterle, L./Guckert, M./Han, T. A./Lewis,
P. R./Milanovic, K., Payne, T./Perret, C./Pitt,
J./Powers, S. T./Urquhart, N./Wells, S.,
“Trusting Intelligent Machines: Deepening
Trust Within Socio-Technical Systems”, 『
IEEE Technology and Society Magazine』,
vol. 37, no. 4, IEEE, 2018, 76-83.

Artz, D./Gil, Y. “A Survey of Trust in Computer
Science and the Semantic Web”, 『Journal of
Web Semantics』, Vol. 5, No. 2, SWSA, 2007,
58-71.

Baier, A., “Trust and Antitrust”, 『Ethics』, Vol. 96,
No. 2, The University of Chicago Press, 1986,
231-260.

Bender, E. M./Gebru, T./McMillan-Major,
A./Shmitchell, S., “On the Dangers of
Stochastic Parrots: Can Language Models Be
Too Big?”, 『Proceedings of the 2021 ACM
conference on fairness, accountability, and
transparency』, 2021, 610-623.

Bodó, B., “Mediated Trust: A theoretical Framework
to Address the Trustworthiness of
Technological Trust Mediators”, 『New Media
& Society』, Vol. 23, No. 9, SAGE, 2021,
2668-2690.

Bommasani, R., Klyman, K., Longpre, S., Kapoor,
S., Maslej, N., Xiong, B., Zhang, D., & Liang,
P. (2023). “The Foundation Model
Transparency Index”, arXiv preprint
arXiv:2310.12941.

Buolamwini, J./Gebru, T., “Gender Shades:
Intersectional Accuracy Disparities in
Commercial Gender Classification”, 『

- Conference on Fairness, Accountability and Transparency』, 2018, 77-91.
- Coeckelbergh, M., “Can We Trust Robots?”, 『Ethics and Information Technology』, Vol 14, No. 1, Springer, 2012, 53-60.
- de Fine Licht, K./de Fine Licht, J., “Artificial Intelligence, Transparency, and Public Decision-making: Why Explanations are Key When Trying to Produce Perceived Legitimacy”, 『AI & society』, Vol. 35, Springer Science+Business Media, 2020, 917-926.
- Dietz, G./Den Hartog, D. N., “Measuring Trust Inside Organisations”, 『Personnel Review』, Vol. 35, No. 5, Emerald Group Publishing, 2006, 557-588.
- Felzmann, H./Fosch-Villaronga, E./Lutz, C./Tamò-Larriex, A., “Towards Transparency by Design for Artificial Intelligence”, 『Science and Engineering Ethics』, Vol. 26, Springer Science+Business Media, 2020, 3333-3361.
- _____, H./Villaronga, E. F./Lutz, C./Tamò-Larriex, A., “Transparency You Can Trust: Transparency Requirements for Artificial Intelligence between Legal Norms and Contextual Concerns”, 『Big Data & Society』, Vol. 6, No. 1, Sage, 2019, 1-14.
- Floridi, L., “Faultless Responsibility: On the Nature and Allocation of Moral Responsibility for Distributed Moral Actions”, 『Philosophical Transactions of the Royal Society A: Mathematical, Physical and Engineering Sciences』, The Royal Society Publishing, 2016, 1-13.
- Floridi, L./Sanders, J. W., “On the Morality of Artificial Agent”, 『Minds and Machines』, Vol 14, Springer, 2004, 349-379.
- Fountain, J. E., “The Moon, the Ghetto and Artificial Intelligence: Reducing Systemic Racism in Computational Algorithms”, 『Government Information Quarterly』, Vol. 39, No. 2, Elsevier, 2022, 681-690.
- Gabriel, I., “Artificial Intelligence, Values, and Alignment”, 『Minds and Machines』, Vol. 30, No. 3, Springer Science+Business Media, 2020, 411-437.
- Henderson, P./Li, X./Jurafsky, D./Hashimoto, T./Lemley, M. A./Liang, P., “Foundation Models and Fair Use”, 『arXiv preprint arXiv:2303.15715』, 2023, 1-61.
- Hill, C./O'Hara, E., “A Cognitive Theory of Trust”, 『Washington University Law Review』, Vol. 87, No. 7, Washington University School of Law, 2006, 1717-1796.
- Jacovi, A./Marasović, A./Miller, T./Goldberg, Y., “Formalizing Trust in Artificial Intelligence: Prerequisites, Causes and Goals of Human Trust in AI”, 『Proceedings of the 2021 ACM Conference on Fairness, Accountability, and Transparency』, 2021, 624-635.
- Jennings, W./Stoker, G./Valgarðsson, V./Devine, D./Gaskell, J., “How Trust, Mistrust and Distrust Shape the Governance of the COVID-19 Crisis”, 『Journal of European Public Policy』, Vol. 28, No. 8, Taylor & Francis, 2021, 1174-1196.
- Jones, S. L./Shah, P. P., “Diagnosing the Locus of Trust: A Temporal Perspective for Trustor, Trustee, and Dyadic Influences on Perceived Trustworthiness”, 『Journal of Applied Psychology』, Vol. 101, No. 3, American Psychological Association, 2016, 392-414.
- Kemper, J./Kolkman, D., “Transparent to Whom? No Algorithmic Accountability without a Critical Audience”, 『Information, Communication & Society』, Vol. 22, No. 14, Routledge, 2019.

- 2081-2096.
- Laux, J./Wachter, S./Mittelstadt, B., “Trustworthy Artificial Intelligence and the European Union AI act: On the Conflation of Trustworthiness and Acceptability of Risk”, 『Regulation & Governance』, Vol 18, No. 1, John Wiley & Sons, 2024, 3-32.
- Lewis, J. D./Weigert, A., “Trust as a Social Reality”, 『Social Forces』, Vol. 63, No. 4, Oxford University Press, 1985, 967-985.
- Mal, C. I./Davies, G./Diers-Lawson, A., “Through the Looking Glass: The Factors That Influence Consumer Trust and Distrust in Brands”, 『Psychology & Marketing』, Vol. 35, No. 3, John Wiley & Sons, 2018, 936-947.
- Mayer, R. C./Davis, J. H./Schoorman, F. D., “An Integrative Model of Organizational Trust”, 『Academy of Management Review』, Vol 20, No. 3, Academy of Management, 1995, 709-734.
- O'Neill, O., “Trust and Accountability in a Digital Age”, 『Philosophy』, Vol. 95, No. 1, Cambridge University Press, 2020, 3-17.
- Reinhardt, K., “Trust and Trustworthiness in AI Ethics”, 『AI and Ethics』, Vol. 3, No. 3, Springer, 2023, 735-744.
- Ryan, M., “In AI We Trust: Ethics, Artificial Intelligence, and Reliability”, 『Science and Engineering Ethics』, Vol. 26, No. 4, Springer, 2020, 2749-2767.
- Schiff, K. J./Schiff, D. S./Adams, I. T./McCrain, J./Mourtgos, S. M., “Institutional Factors Driving Citizen Perceptions of AI in Government: Evidence from a Survey Experiment on Policing”, 『Public Administration Review』, American Society for Public Administration, 2023, 1-17.
- Schoorman, F. D./Mayer, R. C./Davis, J. H., “An Integrative Model of Organizational Trust: Past, Present, and Future”, 『Academy of Management Review』, Vol. 32, No. 2, Academy of Management, 2007, 344-354.
- Shapiro, D. L./Sheppard, B. H./Cheraskin, L., “Business on a Handshake”, 『Negotiation Journal』, Vol. 8, No. 4, MIT Press, 1992, 365-377.
- Siau, K./Wang, W., “Building Trust in Artificial Intelligence, Machine Learning, and Robotics”, 『Cutter Business Technology Journal』, Vol. 31, Cutter Consortium, 2018, 47-53.
- Söllner, M./Hoffmann, A./Leimeister, J. M., “Why Different Trust Relationships Matter for Information Systems Users”, 『European Journal of Information Systems』, Vol. 25, Taylor & Francis, 2016, 274-287.
- Spitale, G./Biller-Andorno, N./Germani, F., “AI Model GPT-3 (Dis)informs Us Better than Humans”, 『Science Advances』, Vol. 9, No. 26, Science, 2023, 1-9.
- Tamò-Larrieux, A./Guitton, C./Mayer, S./Lutz, C., “Regulating for Trust: Can Law Establish Trust in Artificial Intelligence?”, 『Regulation & Governance』, Vol. 18, No. 3, John Wiley & Sons, 2024, 780-801.
- Thiel, D., “Identifying and Eliminating CSAM in Generative ML Training Data and Models”, 『Stanford Digital Repository』, Stanford Internet Observatory Cyber Policy Center, 2023, 1-16.
- Toreini, E./Aitken, M./Coopamootoo, K./Elliott, K./Zelaya, C. G./Moorsel, A. v., “The Relationship between Trust in AI and Trustworthy Machine Learning Technologies”, 『Proceedings of the 2020 Conference on Fairness, Accountability, and Transparency』, 2020, 272-283.

- Vetter, D./Amann, J./Bruneault, F./Coffee, M./Düdder, B./Gallucci, A./ Gilbert, T. K./Hagendorff, T./van Halem, I./Hickman, E./Hildt, E./ Holm, S./Kararigas, G./Kringen, P./Madai, V. I./Wiinblad Mathez, E./Tithi, J. J./Westerlund, M./Wurth, R., “Lessons Learned from Assessing Trustworthy AI in Practice”, 『Digital Society』, Vol. 2, No. 35, Springer Science+Business Media, 2023, 1-25.
- von Eschenbach, W. J., “Transparency and the Black Box Problem: Why We Do Not Trust AI”, 『Philosophy & Technology』, Vol 34, Springer Science+Business Media, 2021, 1607-1622.
- Wieringa, M., “What to Account for When Accounting for Algorithms: a Systematic Literature Review on Algorithmic Accountability”, 『Proceedings of the 2020 Conference on Fairness, Accountability, and Transparency』, 2020, 1-18.
- Yang, R./Wibowo, S., “User Trust in Artificial Intelligence: A Comprehensive Conceptual Framework”, 『Electronic Markets』, Vol. 32, No. 4, Springer Science+Business Media, 2022, 2053-2077.
- Zicari, R. V./Brodersen, J./Brusseau, J./Düdder, B./Eichhorn, T./Ivanov, T./Kararigas, G./Kringen, P./McCullough, M./Möslein, F./Mushtaq, N./Roig, G./Stürtz, N./Tolle, K./Tithi, J. J./Halem, I. v./Westerlund, M., “Z-Inspection®: A Process to Assess Trustworthy AI”, 『IEEE Transactions on Technology and Society』, Vol 2, No. 2, IEEE, 2021, 83-97.

<ABSTRACT>

A Conceptual Framework for the Trust in Artificial Intelligence in AI Governance and Policy Typology

Jisuk Woo, Suji Kim

As artificial intelligence (AI) becomes increasingly prevalent, policy efforts to foster trust in AI as a prerequisite for its acceptance are emerging. However, critical questions remain unanswered regarding the precise definition of trust in AI, its formation process, and the potential role of policy intervention in fostering such trust. Through a theoretical and conceptual review, this study defines trust in AI as “a state in which users accept the risk of being vulnerable to AI based on a comprehensive assessment of the trustworthiness of the AI technologies and AI companies.” This study also divides approaches to AI trust into "risk-reducing" and "trustworthiness-building" and divides the object of users' trust into AI technologies and AI companies, and finally categorizes AI trust policies into four types: enhanced, complying, explanatory, and participatory. The enhanced policy and complying policy are based on the risk-reducing approach, focusing on technical measures to reduce the risk level of artificial intelligence(enhanced), or aiming to eliminate risk factors that may arise during the AI development process in companies(complying). The explanatory policy and participatory policy are based on the trustworthiness-building approach, focusing on evaluating and improving the trustworthiness of AI, encouraging the provision of information related to the trustworthiness of AI technologies to users(explanatory), or creating an environment where users can assess the trustworthiness of AI companies and participate in decision-making processes(participatory). Through a study of the conceptual framework of trust and a typology of AI trust policies, this study highlights the need for AI trust policies to focus on creating an environment where users can actively evaluate the trustworthiness of AI technologies and companies and participate in the decision-making process, alongside efforts to reduce the risks of AI.

Keywords : 인공지능(Artificial Intelligence), 신뢰(Trust), 신뢰성 있는 인공지능(Trustworthy AI), 거버넌스(Governance), 위험(Risk), 기술 규제(Regulation of Technology), 정책 유형(Policy Typology)