

2 강

AI 법규제의 기초 이론

Theoretical Foundations of AI Regulation

<https://github.com/YangGuiBee/AIG2>

2026학년도 2학기 · 담당교수 양희정

<https://yangguibee.github.io>

guibee@konkuk.ac.kr

COURSE · 2026-2

09.10

1강 요약

AI거버넌스의 계보

- 어원은 '배의 키를 잡다'
- 1990년대 기업 지배구조
- 2000년대 IT 거버넌스
- 2020년대 AI 거버넌스

→ 통치가 아니라 다중 이해관계자 방향 설정

AI거버넌스의 핵심

- 윤리는 방향, 법은 강제, 표준은 이행
- EU AI Act
위험을 네 단계로 나눈 규정
- 한국 AI 기본법
진흥과 규제를 함께 담은 기본법

→ 같은 위험을 서로 다르게 다룬다

AI표준과 연구

- ISO/IEC JTC 1/SC 42 : AI 국제표준 기구
- ISO/IEC 42001 AI 경영시스템 실무지침
- 지금은 규범 형성기의 한복판

→ 미해결 과제가 곧 연구 주제

1강의 질문 — “AI거버넌스를 위한 새로운 법이 왜 필요한가?”

2강 구성

왜 AI에는 새로운 법이 필요한가?정당성 → 방식 → 가치 → 연구

1 · 법경제학

규제의 정당성은 어디서 오나?

- (1) 시장실패의 유형
: 정보 비대칭, 외부성, 공공재
- (2) 예방원칙
- (3) 규제실패

2 · 규제 유형론

어떤 방식으로 규제하는가?

- (1) 규제의 유형
: 명령 통제, 성과기반, 공동, 자율
- (2) 국가별 규제
- (3) 브뤼셀 효과
- (4) 캘리포니아 효과

3 · 윤리와 신뢰

어떤 가치를 담는가?

- (1) 인공지능기본법 제정
- (2) 윤리와 신뢰
- (3) 윤리 원칙
- (4) 신뢰 구성요소
- (5) 신뢰의 법률적 구현

4 · 선행연구

- (1) AI 거버넌스 정책 형성과정
- (2) AI 윤리 저작권 규제체계
- (3) AI시대 인공지능기본법과 윤리
- (4) AI 윤리 법의접점
- (5) AI 기술 윤리성 인식척도 개발
- (6) AI 윤리원칙 분류모형 윤리 측정지표
- (7) AI 로봇위험성 유형별 측정지표

핵심

- ① 규제는 시장실패가 있을 때 정당화된다
- ② 각 나라별로 다양한 규제 방식의 조합을 선정한다
- ③ 윤리는 이상, 신뢰는 그 이상을 보증하는 장치이다

규제의 정당성

시장경제의 전제는 자유로운 거래가 자원을 가장 효율적으로 배분한다는 것. 따라서 국가의 개입은 예외이며, 그 예외를 정당화하는 사유가 필요.

법의 대안

대안	작동 원리	AI 분야의 실제
시장의 힘	나쁜 제품은 소비자가 외면한다	이용자는 모델의 편향을 알 수 없다(정보의 비대칭)
기업 자율	평판 손실을 피하려 스스로 규율한다	선도기업만 참여하고 후발주자는 무임승차한다
기술 개선	문제를 기술로 해결한다	어떤 지표를 쓸지가 이미 가치 판단이다
사후 배상	손해가 나면 책임을 묻는다	인과관계 입증 어렵고 회복이 불가능하다

규제의 정당성 논거

① 효율성 논거 (법경제학)

"시장이 스스로 최적을 찾지 못하므로 개입이 사회적 총후생을 높인다."
→ 비용관 편익을 계산

② 권리 논거 (기본권론)

"효율과 무관하게 침해되면 안 되는 가치가 있다."
→ 인간 존엄, 차별 금지, 프라이버시

법의 대안에 대한 실패하는 조건이 존재한다. 경제학은 이를 시장실패라 부른다. 규제의 정당성은 여기서 나온다.

EU AI Act는 효율성 논거와 권리 논거를 결합.

(1) 시장실패의 유형

자유로운 거래에 맡겨두면 사회적으로 바람직한 결과가 나오지 않는 시장실패 → AI는 세 유형을 동시에 보유

(1-1) 정보 비대칭

거래 당사자 한쪽이 훨씬 많이 알고 있다.

AI에서 개발자는 학습 데이터와 오류율과 한계를 인지하나, 이용자는 결과만 본다.

본질적으로 블랙박스인 딥러닝 모델이 이 격차를 구조적으로 만든다.

해결책 → 정보 제공
: 표시, 고지, 문서화, 설명 의무

(1-2) 외부성

거래 당사자 아닌 제3자가 비용을 떠안는다.

AI에서 딥페이크 피해자, 채용 탈락자, 학습 데이터 원권리자들은 계약 관계에 없으므로 그 비용은 가격에서 제외된다.

해결책 → 사전 요건과 책임
: 영향평가/위험관리, 배상

(1-3) 공공재

모두가 이득을 보지만 누구도 비용을 회피한다.

AI에서 안전 연구, 평가 벤치마크, 사고 데이터베이스, 국제표준(SC42 표준화활동) 등으로 개별 기업에는 투자 유인이 없다.

해결책 → 공적 공급
: AI안전연구소, 표준, 공공데이터

정보 비대칭은 AI기본법 제31조와 EU 제50조, 외부성은 AI기본법 제34조와 제35조, 공공재는 AI기본법 제12조와 제14조에 대응

(1-1) 정보 비대칭

중고차 시장의 교훈

판매자는 차의 결함을 알지만 구매자는 모름. 구매자는 속을 위험을 감안해 평균 품질만 가정해 값을 매기고, 좋은 차를 가진 판매자는 시장을 떠남.
남는 것은 불량품(lemon)뿐임.

핵심 — 정보 격차는 단순히 불공정이 아니라 시장 자체를 붕괴시키는 문제.

AI의 심각성

- ① 검증 불가 — 중고차는 정비소 확인 가능, AI 모델 편향은 외부 확인 방법 없음
- ② 개발자도 모름 — 판매자조차 그 결과가 나온 이유를 모르는 경우 있음
- ③ 사후 발현 — 채용 AI의 성별 편향은 수년 누적 후에야 통계로 확인
- ④ 반복·확산 — 한 번의 결함이 수백만 건 결정에 동일 적용

정보 격차를 줄이는 4단계 방법

단계	수단	근거 조항
1단	존재 고지	AI기본법 제31조 제1항 · EU 제50조
2단	생성물 표시	AI기본법 제31조 제2항 및 제3항
3단	기술문서 작성	EU 제11조 · 부속서 4 · 제53조
4단	결과 설명	AI기본법 제34조 · EU 제13조 및 제86조

주의 · 단계가 올라갈수록 난이도 상승
1~2단은 표시만으로 가능하나 3~4단은 내부 공개 필요.
실무 저항이 크고 기술적 구현 필요.
연구 논점 — 4단(설명)에서 충실성과 이해가능성은 상충.
정확한 설명은 어렵고 쉬운 설명은 부정확.

(1-2) 외부성, (1-3) 공공재

외부성 — 계약 밖의 피해자

거래는 양 당사자가 이득을 볼 때 성립한다. 그런데 그 거래로 제3자가 비용을 떠안으면 그 비용은 가격에 반영되지 않고, 시장은 과잉 생산한다.

계약 밖의 제3자	왜 당사자가 아닌가?
딥페이크 피해자	서비스를 이용한 적조차 없다
채용 탈락자	고객은 기업이고 지원자는 당사자가 아니다
학습 데이터 권리자	기사와 이미지가 쓰였으나 계약이 없다(저작권 이슈)
정보환경 전체	허위정보 확산은 사회 전체의 비용이다

해결책은 2개의 방향.
사전에는 영향평가와 위험관리로 비용을 내부화한다(AI기본법 제34조와 제35조, EU 고위험 요건). 사후에는 책임 귀속으로 배상한다.

공공재 — 아무도 안 만드는 것

비배재성으로 막을 수 없고 같이 써도 줄지 않는 재화인 공공재는 모두가 이득을 보지만, 누구도 비용을 내려 하지 않고, 시장은 과소 공급한다.

AI 분야의 공공재	왜 유인이 없는가?
안전 연구	공개되면 모든 기업이 무료로 쓴다
평가 벤치마크	산업 전체에 이득이나 개별 유인이 없다
사고 데이터베이스	사고 공유는 경쟁상 불리하다
국제표준	참여는 비용이고 성과는 공유된다
학습용 공공데이터	초기구축비 과중

해결책은 공적 공급.
AI기본법 제11조 정책센터, 제12조 AI안전연구소, 제14조 표준화, 제15조 학습용데이터 시책이 여기에 해당한다. 진흥 조항이 실은 공공재 공급의 경제 논리다.

(2) 예방원칙

시장실패는 이미 일어난 실패를 근거로 하지만, AI의 피해는 아직 일어나지 않았고 언제 어떻게 일어날지도 모르는 바, 이 공백을 메우는 논리가 예방원칙.

" 과학적 불확실성은 조치를 미루는 이유가 아니다"

심각하거나 되돌릴 수 없는 피해의 우려가 있을 때, 인과관계가 과학적으로 완전히 입증되지 않았더라도 예방적 조치를 취할 수 있다는 원칙.

남용 방지 3요건

- 중대성 — 사소한 불편이 아니라 생명과 신체와 기본권 수준의 피해
- 비가역성 — 사후 배상으로 원상회복이 불가능
- 비례성 — 조치는 위험 수준에 비례해야 하며 전면 금지가 기본값 아님

예방법은 독일 환경법의 사전배려원칙에서 출발해서
리우선언(1992년) 제15원칙을 거쳐
EU의 환경정책 조약 제191조 제2항으로 성문화.

조문에서의 예방원칙

조항	예방원칙이 드러나는 방식
EU 제5조 금지 AI	피해 입증 없이 유형 자체를 금지한다. 예방원칙의 가장 강한 형태다.
EU 제3장 고위험 요건	사고 발생 전에 위험관리와 데이터 품질과 문서화를 미리 요구한다.
AI기본법 제2조 및 제 33조	생명 and 신체와 기본권에 중대한 영향을 미칠 우려가 기준이다. 피해 발생이 아니라 우려가 요건이다.
AI기본법 제35조 영향 평가	사업 개시 전에 기본권 영향을 스스로 평가한다.

미국 학계의 주된 반론. 불확실성을 근거로 하므로 범위가 무한 확장
될 수 있고, 예방 조치 자체의 비용과 기회손실은 계산되지
않으며, 규제하지 않는 것의 위험은 평가되지 않는다.

(3) 규제 실패

시장실패는 규제의 필요성을 말할 뿐 규제의 성공을 보장하지 않는다. 두 실패를 비교해서 더 작은 실패를 고르는 것이 실제 정책 판단이다.

규제가 실패하는 다섯 가지 유형

실패 유형	내용과 처방
정보 부족	규제자가 기술을 기업만큼 이해하지 못한다. 규제자도 정보 비대칭의 약자다. AI기본법 제12조 AI안전연구소나 EU의 AI Office가 그 처방이다.
규제 포획	규제받는 산업이 규제 설계에 영향력을 행사한다. 전문성이 산업에 몰려 있어 구조적으로 불가피한 면이 있다.
속도 불일치	입법은 수년, 기술은 수개월이다. EU초안(2021.4)은 범용 AI 조항을 뒤늦게 삽입해야 했다. 성과 기반 규제의 논거다.
준수 비용의 비대칭	대기업은 전담팀으로 흡수하고 스타트업은 감당하지 못한다. 규제가 진입장벽이 된다. EU 제62조 특례의 이유다.
규제 회피	규제가 약한 관할로 개발과 서비스를 옮긴다. EU 제2조 역외적용이 필요해진 이유다.

규제 판단 질문

규제 여부는 이념이 아니라 비교의 문제다. 세 가지를 순서대로 묻는다.

첫째, 시장실패가 실재하는가? 정보비대칭,외부성,공공재 유형 중 어느 것 인지 특정할 수 있어야 한다.

둘째, 규제실패가 시장실패보다 작은가? 어느 실패가 발생할지 그 크기를 따진다.

셋째, 다른 수단은 없는가? 정보 공개, 표준, 인증, 보험과 사후책임법이 있다.

이 세 질문에 답하는 규제 찬반 주장이 논증이 된다

(1) 규제의 유형

"규제할 것인가?"는 예/아니오로 딱 떨어지는 것이 아니고, 국가의 개입 강도에 따라 최소 네 가지 방식이 있고, 실제 법은 이 4개의 유형이 혼합됨.

◀ 국가 개입이 강하고 예측가능성이 높다

민간 자율이 강하고 유연성이 높다 ▶

(1-1) 명령·통제 규제

국가가 수단까지 지정하고 위반 시 제재

형식 : 무엇을 해야 한다 또는 하지 말아야 한다.

- 예시
- EU 제5조 금지 AI
 - EU 고위험 마킹 의무
 - AI기본법 제31조 표시 의무

강점 : 명확성
약점 : 경직성

(1-2) 성과 기반 규제

국가는 목표만 정하고 방법은 사업자 선택

형식 : 어떤 수준을 달성한다.

- 예시
- EU 제9조 위험관리체계
 - EU 제15조 정확성과 견고성
 - AI기본법 제32조 안전성 확보

강점 : 기술 중립성
약점 : 준수 판정의 어려움

(1-3) 공동 규제

법이 목표를 정하고 기준은 민간 표준 위임

형식 : 표준을 따르면 적합으로 추정.

- 예시
- EU 제40조 적합성 추정
 - EU 제56조 행동규약
 - ISO/IEC 42001 인증

강점 : 전문성 활용
약점 : 규제 포획

(1-4) 자율 규제

법적 강제력은 없이 민간 스스로 기 준수립

형식 : 우리는 이렇게 하겠다.

- 예시
- 기업 AI 윤리원칙
 - 자체 레드팀과 모델 카드
 - 업계 가이드라인

강점 : 유연성
약점 : 무임승차와 윤리 워싱

(1-1) 명령·통제, (1-2) 성과 기반

조문의 동사로 유형 판별 : "표시한다 · 금지한다"는 명령·통제, "확보한다 · 적절한 수준을 유지한다"는 성과 기반

비교 항목	명령·통제 규제 (Command-and-Control)	성과 기반 규제 (Performance-Based)	실무 판별 신호
규범의 형식	수단·행위를 특정한다 "~을 하여야 한다 / ~해서는 아니 된다"	달성해야 할 상태를 특정한다 "~을 확보하여야 한다 / 적절한 수준을 유지"	조문의 목적어가 행위인가 상태인가
EU 조항 예	제5조 금지 AI · 제50조 투명성 표시 의무 제49조 EU 데이터베이스 등록	제9조 위험관리체계 · 제10조 데이터 거버넌스 제15조 정확성·견고성·사이버보안	별표(Annex)에 구체 목록이 딸려 있는가
한국법 조항 예	제31조 투명성 확보 의무(표시·고지)	제32조 안전성 확보 의무 · 제33·34조 사업자 책무 제35조 영향평가	이행 방법을 시행령에 위임했는가
준수 입증 방법	했다 / 안 했다는 사실 확인 화면 캡처 · 표시 문구 · 등록번호	과정의 문서화가 곧 준수 증거 위험대장 · 테스트 리포트 · 회의록 · 개선 이력	감독기관이 요구할 산출물의 성격
기업의 실패 지점	조문을 몰라서 누락한다 → 대응: 의무 목록 체크리스트	했지만 증명하지 못한다 → 대응: 관리체계 구축·기록 보존	ISO/IEC 42001이 필요해지는 지점
기술 변화 대응	취약 — 조문 개정이 필요하다 새 기술이 문언에 포섭되지 않는다	강함 — 문언이 기술 중립적이다 다만 해석 부담이 사업자에게 이전된다	블록 1의 속도 불일치 문제와 연결

EU는 별표로 구체 목록을 붙여 명령·통제 비중이 높다. 한국 AI기본법은 이행 방법을 시행령·가이드라인에 위임해 성과 기반 비중이 높다.
→ 같은 사업자라도 EU에서는 목록 대조, 한국에서는 문서 증명이 방어의 핵심이 된다.

(1-3) 공동 규제, (1-4) 자율 규제

공동규제의 법적 효력

단계	무엇이 일어나는가?	구체적 내용
1단계 : 법	목표만 규정한다	EU 제15조는 적절한 수준의 정확성과 견고성만 요구한다
2단계 : 위임	표준화를 요청한다	집행위원회가 유럽 표준화 기구에 표준 개발을 위임한다
3단계 : 개발	민간이 기준을 작성한다	ISO/IEC SC 42의 성과물을 참조하고 정합시킨다
4단계 : 효력	적합성을 추정한다	관보에 게재된 조화표준을 준수하면 법 요건을 충족한 것으로 추정한다

공동규제의 효과

- 표준화 참여가 곧 규범 형성 참여가 된다
- 입증 부담이 역전되어 감독기관이 부적합을 입증해야 한다
- 규제 포획의 통로가 열린다(민주적 정당성)

자율 규제와 한계

법적 강제력 없이 민간이 스스로 기준을 만들고 공표. 국내 주요 기업의 AI 원칙과 레드팀과 표시 정책.

기업이 자발적으로 하는 이유: 평판, 향후 규제 선점, 투자자와 조달의 요구, 소송 위험 완화다.

첫째 한계는 무임승차. 성실한 기업만 비용을 부담하고, 준수하지 않은 기업이 가격 우위를 얻는다.

둘째 한계는 윤리 워싱. 선언은 화려하나 검증 수단이 없다. 측정할 수 없는 원칙은 준수를 확인할 수 없다.

이러한 한계 보완을 위한 측정지표 연구가 진행

(2) 국가별 규제

수평적 규제는 전 분야를 하나의 법으로 규율하고, 수직적 규제는 의료와 금융과 고용 등 분야별로 개별 규율

관할	접근 방식	주된 규제 유형	핵심 규범	특징과 한계
EU	수평적	명령·통제와 공동 규제	Regulation (EU) 2024/1689. 위험 기반 네 단계에 의료, 금융, 고용, 교육 등 범용 AI를 별도 축으로 둔다.	세계 최초 포괄 규제로 한계는 규제 복잡성(불명확성)이다.
미국	수직적	성과 기반과 자율 규제	연방 포괄 규제가 없다. 위험관리 프레임워크는 자발적이며 주 단위 규제가 확산된다.	혁신 친화적이나 관할별 파편화가 한계다.
영국	수직적	성과 기반과 기존 기관 활용	단일 법률 대신 기존 부문 규제기관에 원칙 적용을 위임한다.	유연(저비용)하나 규제 공백이 가능하다.
중국	수직적	강한 명령·통제	알고리즘 추천과 딥합성(Deep Synthesis)과 생성형 AI에 개별 관리규정을 순차 시행한다.	집행력이 강하나 목적이 상이하다.
캐나다	수평적	명령·통제 지향	인공지능 및 데이터법을 추진하며 EU식 포괄 접근을 참조한다.	EU 모델을 따르나 입법이 지연되고 있다.
대한민국	혼합 (형식은 수평적)	성과 기반과 공동 규제에 진흥 조항이 병존한다	「인공지능 발전과 신뢰 기반 조성 등에 관한 기본법」이며 6장 43조로 구성된다. 2026년 1월 22일 시행, 7월 21일 개정법 시행.	포괄 형식에 낮은 규제 강도를 결합했다. 쟁점은 고영향 AI 개념의 명확성이다.

(3) 브뤼셀 효과 (1/2)

Anu Bradford의 『The Brussels Effect』 (2020)의 명제 : EU는 군사력도 통상 압박도 쓰지 않고 전 세계 규범을 바꾼다.

기업이 스스로 EU 기준을 전 세계에 적용한다

EU가 다른 나라에 우리 법을 따르라고 요구하는 것이 아니다. 기업이 비용 계산을 하고 스스로 따른다.

- ① EU 시장은 포기할 수 없을 만큼 크다 — 진출을 안 하는 선택지가 없다
- ② 제품·서비스를 지역별로 두 벌 만들면 개발·운영비가 이중으로 든다
- ③ 그래서 가장 엄격한 기준(EU)에 맞춘 하나의 제품을 전 세계에 낸다
- ④ 결과적으로 EU 기준이 사실상의 글로벌 표준이 된다
 - 사실상(de facto) 브뤼셀 효과
- ⑤ 이후 각국 정부가 입법으로 모방한다
 - 법률상(de jure) 브뤼셀 효과

선례 · GDPR(개인정보 규범)에서 이미 전 세계 기업이 EU 기준의 동의·삭제권·DPO 체계를 도입했고, 각국 개인정보법이 그 구조를 따라갔다.
EU AI Act는 이 경로를 AI에서 반복하려는 시도이나 현황은 확인할 필요

EU 법 적용의 근거

- 첫째, 우리 기업이 실제로 적용받는다.
제2조 역외적용에 따라 EU 시장에 서비스하면 적용된다.
- 둘째, AI기본법 해석의 참조점이 된다.
고영향 AI와 영향평가와 투명성 의무는 EU 개념과 계보를 공유한다.
- 셋째, 표준을 통해 다시 들어온다.
조화표준은 ISO/IEC와 정합되고 국내 기업이 그 표준을 채택한다.
- 넷째, 연구의 언어가 된다.
국내 선행연구 다수가 EU AI Act를 기준으로 삼는다.

(3) 브뤼셀 효과의 조건 (2/2)

브뤼셀 효과가 실현되는 5개 조건에 대한 적용 검토

조건	Bradford의 정의	AI 분야 대입 · 검증	충족 정도	근거 조항 · 사실
① 시장 규모 Market size	규제국 시장이 기업이 포기할 수 없을 만큼 커야 한다	EU는 인구·소득 기준 세계 최대 단일 시장 중 하나. 주요 AI 서비스가 EU 철수를 선택하지 않는다	충족	기업의 실제 진출 행태로 확인
② 규제 역량 Regulatory capacity	규제를 설계·집행할 전문 조직과 제재 수단이 있어야 한다	EU AI Office 설치 · 회원국 감독기관 지정 · 과징금 상한이 매출 기준으로 설정	부분 충족 신설 조직의 실집행 실적은 축적 중	제64조 이하 거버넌스 · 제99조 과징금
③ 엄격한 기준 Stringent standards	규제국 기준이 다른 곳보다 엄격해야 한다 — 그래야 상향 수렴한다	금지 유형을 명시하고 고위험에 사전 요건을 부과. 미국 연방 차원에는 대응 규범이 없다	충족	제5조 금지 · 제III장 고위험 요건
④ 비탄력적 대상 Inelastic targets	규제 대상이 다른 곳으로 옮길 수 없어야 한다	여기가 쟁점이다. 소비자·시장은 옮길 수 없지만 모델 개발·학습은 어디서든 가능하다. 그래서 EU는 역외적용으로 대응했다	조건이 약하다 법으로 보완한 형태	제2조 역외적용
⑤ 비분할성 Non-divisibility	제품·서비스를 지역별로 나눌 수 없어야 한다 — 나눌 수 있으면 EU만 준수하면 된다	가장 취약한 조건. 소프트웨어는 지역별 분기가 물리적 제품보다 쉽다. 다만 단일 모델을 지역별로 다르게 학습·운영하면 비용·품질 관리 부담이 커진다	약함 기업별 판단이 갈린다	GDPR 사례와 결과가 달라질 수 있는 지점

검증 결과 — "AI에서 브뤼셀 효과는 GDPR만큼 강하지 않을 수 있다"

①③은 충족, ②는 부분 충족, ④⑤가 약하다. 즉 결론이 정해진 문제가 아니다 → 이것이 연구할 가치가 있는 질문이라는 뜻이다.

(4) 캘리포니아 효과

규범 확산은 국제기구·EU에서 내려오는 것만이 아니고, 지방정부에서 위로 올라오기도 한다.

한 주(州)의 기준이 전국 기준이 된다

캘리포니아는 미국 최대 소비 시장이다. 캘리포니아 기준을 못 맞추면 그 시장을 잃는다. 그런데 주별로 다른 제품을 만드는 것도 비싸다. 그래서 기업은 캘리포니아 기준으로 통일한다.

고전적 사례 · 자동차 배출가스

캘리포니아가 연방보다 엄격한 배출 기준을 도입 → 제조사가 주별 사양 분리 비용을 피해 전 모델을 상향 → 사실상 전국 기준화 → 이후 다른 주와 연방 규제가 그 수준으로 수렴

구분	내용
공통 조건	큰 시장 + 엄격한 기준 + 지역별 분할 비용
브뤼셀	국가 위(초국가 연합) → 아래로 확산
캘리포니아	국가 아래(지방정부) → 위로 확산
공통 함의	규범 형성의 주체가 중앙정부만이 아니다

AI 분야의 사례

앞 장에서 미국의 특징을 연방 포괄 규제 부재와 주 단위 규제 확산으로 정리했다. 이 구조가 캘리포니아 효과의 전제 조건이다.

- 연방 공백이 주를 규범 주체로 만든다. 포괄 AI 법이 없으므로 실질적 규범은 주 법률에서 먼저 형성된다.
- 캘리포니아와 콜로라도 등이 선행한다.
- 기업은 최고 수준으로 통일한다. 50개 관할별 대응은 비현실적이므로 가장 엄격한 주 기준이 사내 기준이 된다.
- 결과적으로 두 방향의 압력이 겹친다. 위에서는 EU, 아래에서는 주 정부다.

반대 현상도 있다 · **Race to the Bottom** — 규제가 약한 관할로 이동하는 하향 경쟁 규제 회피와 같은 논리다. 상향·하향 중 어느 쪽이 우세한지는 실증의 문제다.

(1) 인공지능법 제정

번호	법안명	발의	노선
1	인공지능 산업 육성 및 신뢰 확보	안철수(국민의힘)	C
2	인공지능 발전과 신뢰 기반 조성	정점식(국민의힘)	C
3	인공지능 산업 육성 및 신뢰 확보	조인철(민주당)	C
4	인공지능 산업 육성 및 신뢰 확보	김성원(국민의힘)	C
5	인공지능 기술 기본법	민형배(민주당)	A
6	인공지능 개발 및 이용	권칠승(민주당)	A
7	인공지능 기본법	한민수(민주당)	A
8	인공지능 책임법	황희(민주당)	B
9	인공지능 발전 진흥과 사회적 책임	배준영(국민의힘)	C
10	인공지능의 발전과 안전성 확보	이훈기(민주당)	B

번호	법안명	발의	노선
11	인공지능 산업 진흥 및 신뢰 확보	김우영(민주당)	C
12	인공지능 산업 육성 및 신뢰 기반 조성	이정헌(민주당)	C
13	인공지능 발전 및 신뢰 보장	황정아(민주당)	C
14	인공지능 산업 진흥 및 이용	이해민(조국혁신당)	A
15	인공지능 산업 진흥	정동영(민주당)	A
16	인공지능 산업 육성 및 신뢰 기반 조성	최민희(민주당)	C
17	인공지능 산업 육성 및 발전	정희용(국민의힘)	A
18	인공지능 진흥	조승래·이인선(민주당·국민의힘)	A
19	인공지능의 안전 및 신뢰 기반 조성	조승래·이인선(민주당·국민의힘)	B

A는 진흥과 육성 중심으로 7건, B는 책임과 안전 중심으로 3건,
C는 육성과 신뢰를 함께 담아 9건이다. C가 최종 채택 노선이다.

법 이름에 신뢰가 들어간 이유
국민 보호 : 신뢰 확보가 선행 / 산업 육성 : 신뢰 없으면 규제 강화 / 국제 경쟁력 :
EU·OECD·유네스코 핵심어 / 사회적 합의 · 정치적 합의

(2) 윤리와 신뢰

윤리는 이상(理想)이고, 신뢰는 그 이상이 지켜지고 있음을 보증하는 장치

윤리(Why) · 무엇이 옳은 AI인가?

AI가 어떤 가치에 따라야 하는가를 정의하는 영역.
옳은 AI가 무엇인지 고민한다. 윤리는 AI의 이상(理想)이다.

- 목적Purpose 왜 이 AI가 인간에게 해를 주지 않아야 하는가
- 기준Principles 공정성 · 인권 · 책임성 · 비차별
- 가치Values 인간 중심의 우선순위

규범 형식 — 선언 · 헌장 · 원칙 · 권고
담당 주체 — 철학자 · 학계 · 국제기구 · 기업 윤리위원회
강제력없음 — 위반해도 제재가 없다

신뢰(Hwo) · 그 이상을 어떻게 보증하는가?

윤리 원칙이 현장에서 실제로 어떻게 구현되는가에 대한 것.
윤리가 지켜지고 있음을 어떻게 증명하는가의 문제다.

- 수단Means 법 · 제도 · 인증 · 규제
- 운영Operation 위험관리 · 감시 · 테스트 · 책임 부여
- 절차Procedures 설명가능성 절차 · 데이터 관리 절차 · 안전성 검증 절차

규범 형식 — 법률 · 시행령 · 표준 · 인증 기준
담당 주체 — 입법부 · 감독기관 · 표준화 기구 · 인증기관
강제력있음 — 과징금 · 시정명령 · 시장 배제

(2) 윤리 → 신뢰

윤리는 무엇이 옳은 AI인지 정의하는 기준이고, 신뢰는 그 기준이 실제 실현되고 있다는 사회의 확신.



(3) 윤리 원칙

전 세계에서 발표하는 AI 윤리원칙 84개 지침의 주요 원칙비교

가장 강하게 수렴한 다섯 원칙

원칙	내용
투명성	설명가능성과 공개와 추적가능성이며 가장 빈번하게 등장한다
정의와 공정성	편향 제거와 차별 금지와 형평성이다
비악의성	해를 끼치지 않을 것이며 안전과 보안을 포괄한다
책임	책임 귀속과 감사가능성과 구제 절차다
개인정보 보호	데이터 보호와 최소 수집과 목적 제한이다

이 다섯이 국제 규범의 공통 기반이 되었다.

다음 장의 신뢰 여섯 구성요소, ISO/IEC 42001의 통제 항목, AI기본법 제31조와 제32조의 의무 구조가 모두 이 다섯에서 파생된다.

문서 간 편차가 큰 원칙

84개 윤리지침 : 전 세계 주요 기관 및 국가에서 발표한 인공지능(AI) 윤리 가이드라인 84개를 종합 분석하여 도출된 글로벌 AI 윤리 기준 및 원칙.

AI 윤리원칙은 국제적으로 5개까지만 합의

방법론으로서의 가치

원상철(2024) 연구는 84개 문서를 수집해 원칙을 코딩하고 빈도와 내용을 분석

국내 기업 윤리원칙을 같은 방식으로 코딩하면 그 자체로 소논문의 가능성

(4) 신뢰 구성요소

신뢰를 확보하라는 의무가 집행 가능해지려면 신뢰가 항목으로 분해되어야 한다.

구성요소	요구되는 상태	근거 조항	대응 실무
안전성	예측 가능한 방식으로 동작하며 위해를 야기하지 않아야 한다	AI기본법 제32조 안전성 확보 · EU 제9조 위험관리 · EU 제15조 견고성	위험 식별과 평가와 완화, 사고 대응 절차
투명성	작동 정보와 위험 수준을 공개해야 한다	AI기본법 제31조 투명성 확보 · EU 제50조 투명성 의무	AI 이용 고지, 생성물 표시, 모델 문서화
책임성	개발자와 제공자와 이용자 간 법적 책임이 분담되어야 한다	AI기본법 제33조와 제34조 사업자 책무 · 제36조 국내대리인	역할과 책임 정의, 계약상 책임 배분
공정성	차별을 방지하고 데이터 편향을 관리해야 한다	AI기본법 제35조 영향평가 · EU 제10조 데이터 거버넌스	편향 평가, 데이터 품질 검증, 집단별 성능 검토
보안성	악의적 이용과 공격 가능성에 대해 방어해야 한다	EU 제15조 사이버보안 · ISO/IEC 42001 부속서 A 통제	레드팀, 적대적 입력 테스트, 접근 통제
인간 중심성	인간이 최종 통제권을 가져야 한다	EU 제14조 인간 감독 · OECD AI 원칙	사람의 개입 지점 설계, 비상 정지, 이의제기 절차

(5) 신뢰의 법률적 구현 (1/3)

① 신뢰 구성요소의 법제화

ISO/IEC 42001과 OECD AI 원칙과 EU AI Act와 동일한 축으로 신뢰 요소를 법에 명시해 사회적 수용성을 확보한다.

법에 명시된 요소	요구되는 상태
안전성	예측 가능하게 동작하며 위해를 야기하지 않을 것
투명성	작동 정보와 위험 수준을 공개할 것
책임성	주체 간 법적 책임을 분담할 것
공정성	차별을 방지하고 데이터 편향을 관리할 것
보안성과 인간 중심성	악의적 이용을 방어하고 인간이 통제권을 가질 것

국제표준과 같은 축을 쓰면 이중 대응 비용이 줄고 인증과 조달에서 상호 인정이 가능해진다.

② 위험 기반 등급별 규제

모든 AI에 같은 의무를 부과하지 않는다. 고위험 이상에 대해서만 사전 인증과 품질관리와 데이터 검증과 로그 의무를 강제한다.

등급	규율 방식과 근거
금지 AI	생체인식 감시와 사회적 신용 점수화 등이고 EU 제5조가 근거다.
고위험 AI	의료와 고용과 금융의 결정 지원이고 EU 제3장과 AI기본법 제33조 이하가 근거다.
중위험 AI	챗봇과 생성형 AI이고 EU 제50조와 AI기본법 제31조가 근거다.
저위험 AI	단순 자동화이며 원칙적으로 자율에 맡긴다.

예방원칙의 비례성 요건이 구현된 형태다. 범용 AI는 이 네 등급과 별도의 축에 놓인다.

(5) 신뢰의 법률적 구현 (2/3)

③ 책임구조의 설계

개발자와 제공자와 이용자, 그리고 정부까지 역할별로 책임을 분담하고 표준화한다.

주체	책임
개발자	데이터 편향과 모델 오류 관리, 고위험 시스템 품질 보증
제공자	서비스 단계의 안정성 확보와 보안 유지
이용자	오용 금지와 허위 데이터 입력 금지
정부	표준 제정과 사고 조사와 제재 집행

AI기본법 제33조와 제34조 사업자 책무, 제36조 국내대리인, EU 제3장 제3절 주체별 의무.

④ 투명성 의무 강화

투명성은 개별 결정을 설명하는 설명성과 체계 정보를 공개하는 공시라는 두 축으로 구현

- AI 사용 고지 의무
 - 상대가 AI임을 알 권리
- AI 결정 설명 요구권
 - 불리한 결정의 근거를 물을 권리
- 데이터 출처 공개
 - 저작권 쟁점과 직결
- AI 생성물 표시
 - 서비스 내 표시와 외부 반출 표시를 구분

AI기본법 제31조 투명성 확보 의무, EU 제13조 정보제공과 제50조 투명성, 제53조 범용 AI 문서화.

⑤ 테스트와 인증 체계

품질과 안전과 보안과 편향을 인증으로 제도화한다. 성과 기반 의무를 증명하는 장치다.

- 경영시스템 인증
 - ISO/IEC 42001 기반으로 조직 인증
- 제품 단위 적합성 평가
 - 제품 인증하며 EU 마킹의 전제
- 분야별 특수 인증
 - 의료용 AI 등 기존 분야 규제와 결합
- 공공조달 우선 구매
 - 인증 제품을 우선 구매해 시장으로 유인

조달은 제재가 아니라 유인이다. 규제 아닌 수단으로 규제 목적을 달성.

(5) 신뢰의 법률적 구현 (3/3)

⑥ 데이터 품질과 편향 관리

모델의 문제는 대개 데이터의 문제로
규제는 모델이 아니라 입력을 규율.

- 데이터 관리 기준을 둔다.
판별형과 생성형 AI 모두에 적용
- 편향의 측정과 개선을 절차로 의무화
- 학습 목적과 정보주체 권리의 균형을 유지
- 적법한 출처의 데이터를 썼는지에 대한
책임을 진다. 저작권 면책 논의와 직결

⑦ 안전성 검증과 사고 보고

사고를 공유하지 않으면 산업전체가 같은 실수
를 반복하나 자발적 공유는 일어나지 않는다.

- 중대한 사고와 오작동을 감독기관에 보고
- 고위험 AI는 사전에 신고하고 사후에 평가
- 국가 차원의 AI 안전 전담 조직이 사고 조사
- 사례를 축적한 위험 데이터베이스를 운영해
산업 전체가 참조

⑧ 공공영역의 모범 의무

국가가 민간에 요구하는 것을 스스로 먼저 지
킨다. 규제의 정당성은 여기서 나온다.

- 행정 결정에 쓰이는 공공 AI는 더 높은
투명성과 설명가능성 기준을 적용
- 공공조달에서 인증받은 AI만 허용하면
조달 기준이 사실상의 시장 기준
- 공공 도입 전에 알고리즘 영향평가를 의무화
하고 AI기본법 제35조의 공공 적용

선행연구 7+7

01. 인공지능 거버넌스와 정책형성과정 연구, 김지원, 2024, 서울대학교 대학원

02. 인공지능 윤리와 저작권의 규제체계 연구, 신용우, 2024, 국회입법조사처 정책연구

03. 인공지능(AI)시대, 인공지능기본법과 윤리, 김경동, 2025, 한국법학회 법학연구

04. 인공지능의 윤리와 법의 접점, 원상철, 2024, 한국법이론실무학회 법이론실무연구

05. 인공지능기술 윤리성 인식 척도개발 연구, 김도연·고영화, 2022, 한국디지털정책학회 디지털융복합연구

06. AI 윤리원칙 분류 모형 및 윤리 측정지표(EMI-AI) 개발, 소순주, 2023, 성균관대학교 대학원

07. AI 로봇의 위험성 유형별 측정지표 개발과 윤리원칙 관계성, 송현경, 2024, 성균관대학교 대학원

08. 인공지능기본법상 '고영향 인공지능'과 관련된 기본권 논의 - EU AI규제법과 비교를 겸하여, 백수원, 2025, 유럽헌법연구

09. 인공지능 거버넌스에서 신뢰 개념에 대한 고찰 및 정책 유형화 연구, 우지숙·김수지, 2024, 경제규제와 법

10. 대학생의 인공지능 윤리의식에 관한 실증연구, 백현기, 2024, 산업융합연구

11. The emergence of artificial intelligence ethics auditing(인공지능 윤리 감사의 부상), Schiff, D. S., 2024, Big Data & Society

12. Auditing large language models: a three-layered approach(LLM 감사: 3계층 접근), Mökander, J., 2024, AI and Ethics

13. 직업규제 영역의 인공지능 기능대체와 고위험성 판단기준 - 직업의 자유 제한 법리에 기초한 기능적 등가성 기준의 제안, 김민규, 2026, 법조

14. 인공지능 시대의 '손해'에 대한 관견(管見) - '정서적 의존' 등의 비재산적 손해를 중심으로, 이수경, 2026, 민사법의 이론과 실무